

VERGLEICH VON DATENGETRIEBENEN CLUSTERINGMETHODEN IM CIFAR10- UND MNIST-DATENSATZ

von Emre Kaplan, Bünyamin Budak und Maxim Speczyk

Motivation



1,5 BILLIONEN DOLLAR
VERLUST DURCH STILLSTÄNDE



2,3 MILLIONEN DOLLER
PRO STUNDE KOSTET STILLSTAND



EXTREME MENGE AN DATEN DIE
DIES VERHINDERN KÖNNTEN

Motivation & Zielsetzung

Supervised Learning reicht nicht aus



Wir benötigen Unsupervised Learning

Wie gut sind moderne Clustering-
Methoden?

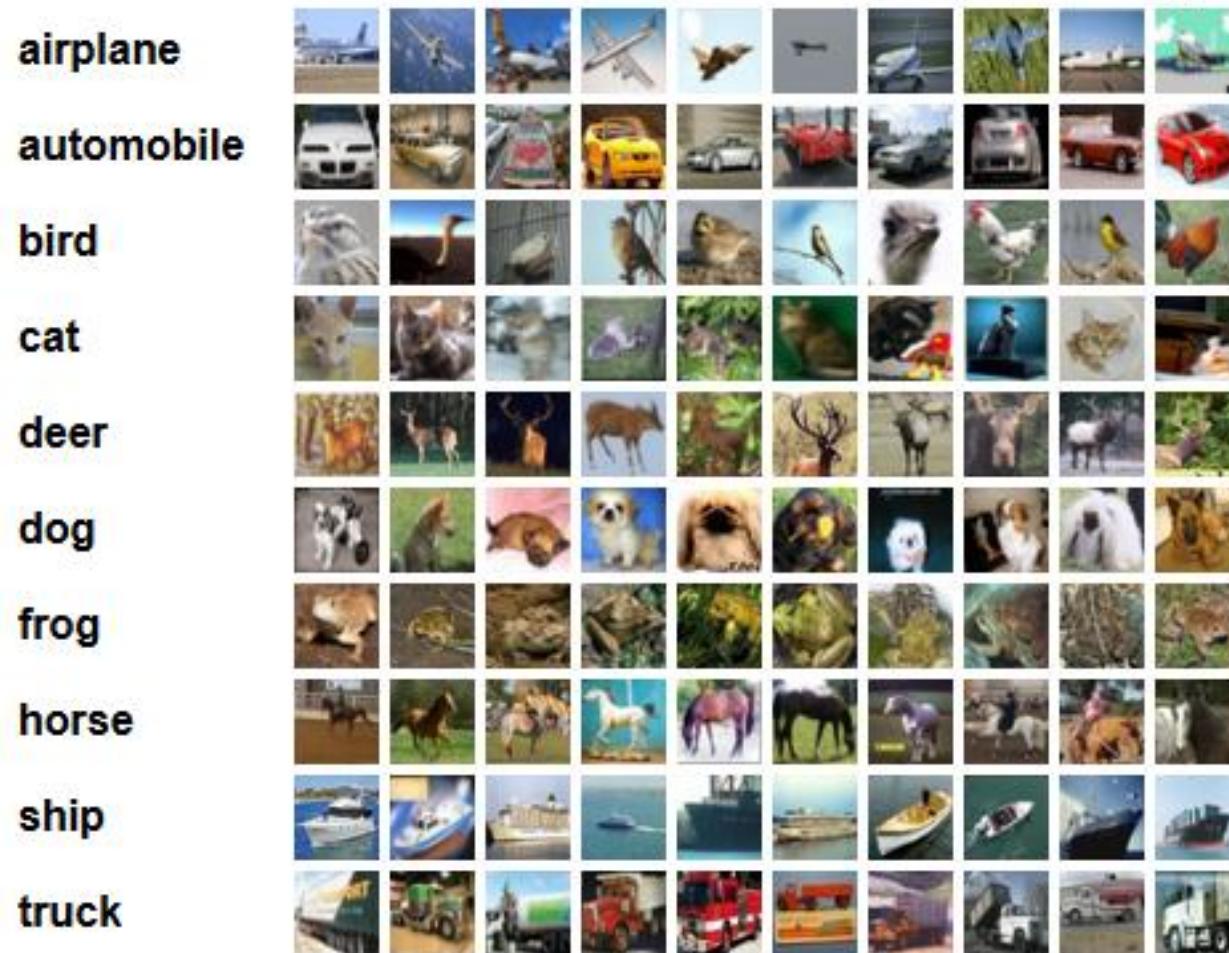
Datensätze - MNIST



<https://de.wikipedia.org/wiki/MNIST-Datenbank#/media/Datei:MnistExamples.png>

- Handgeschrieben Ziffern
 - 28 x 28 Pixel
 - Graustufen
- > Geringe Komplexität

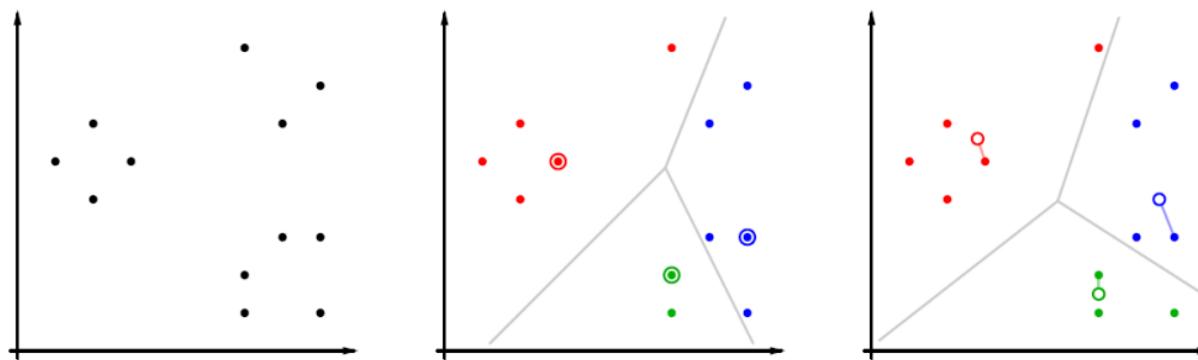
Datensätze – CIFAR10



<https://www.cs.toronto.edu/~kriz/cifar.html>

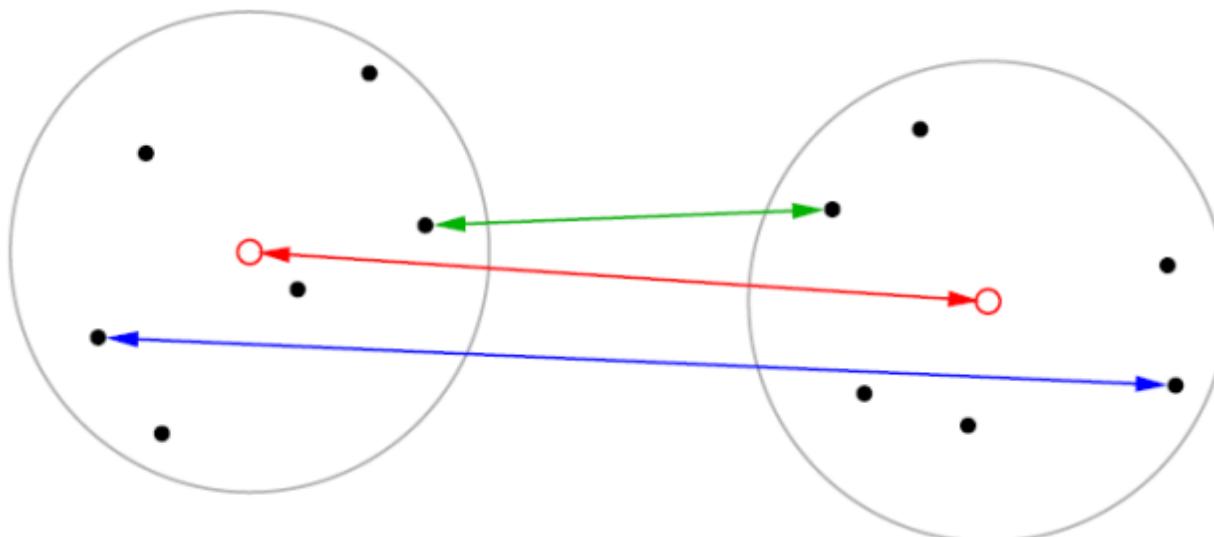
- Realistische Objekte
 - 32×32 Pixel
 - RGB
- > Hohe Komplexität & Varianz

K-means - Clustering Verfahren



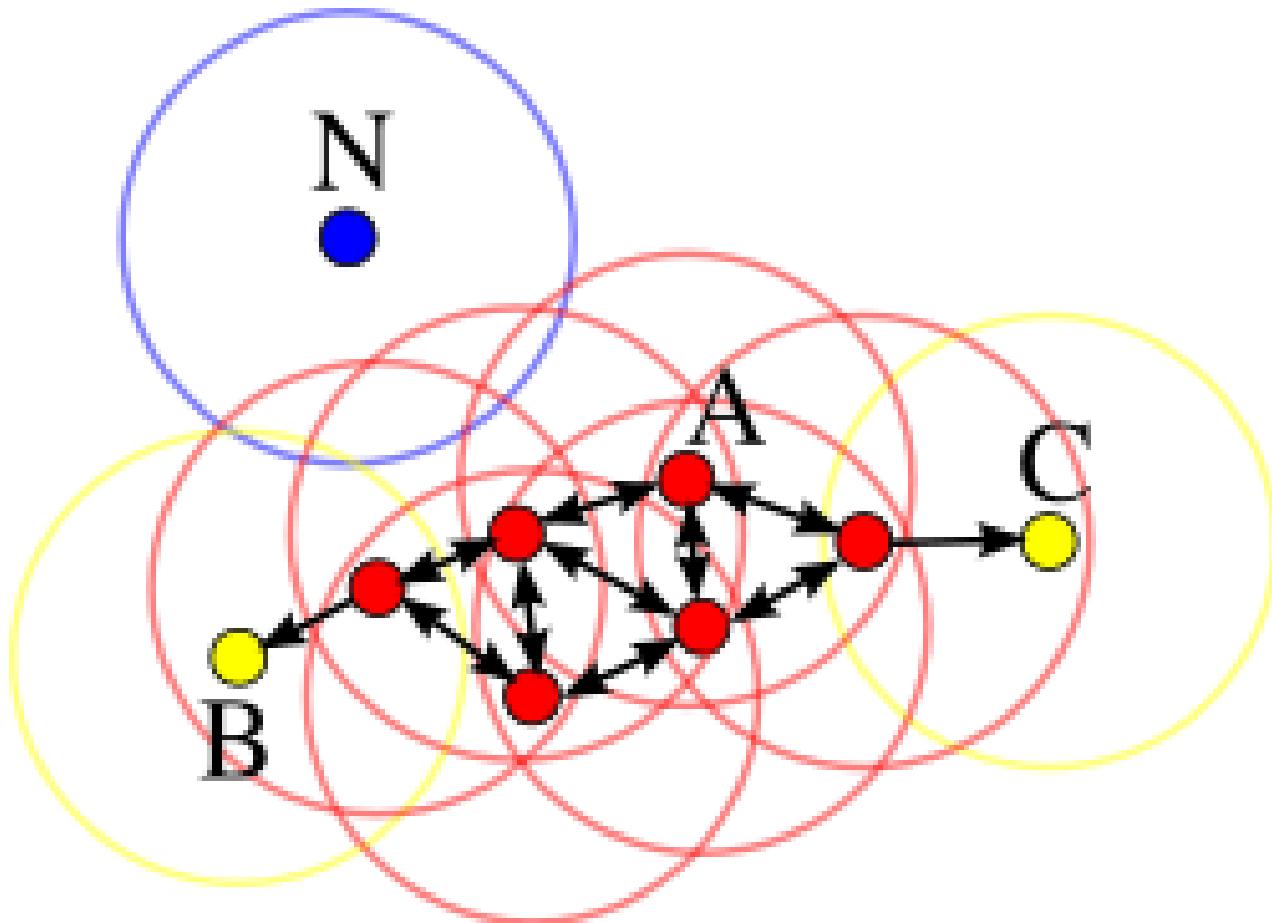
- iteratives, zentroid-basiertes Verfahren.
- Minimierung der quadratischen Abstände zum Cluster-Mittelpunkt.
- Wechselspiel:
Datenpunkt-Zuweisung \leftrightarrow Update der Zentren.
- Vorteile: Effizienz & Einfachheit
- Nachteile: Ergebnisse hängen stark vom Startpunkt ab, k muss festgelegt sein

Hierarchisch - Clustering Verfahren



- Bottom-Up-Ansatz: Jeder Punkt startet als eigenes Cluster.
- Schrittweise Verschmelzung der ähnlichsten Cluster.
- Vorteil: Deterministisch (liefert immer das gleiche Ergebnis, kein Zufall).
- Nachteil: Hoher Rechenaufwand

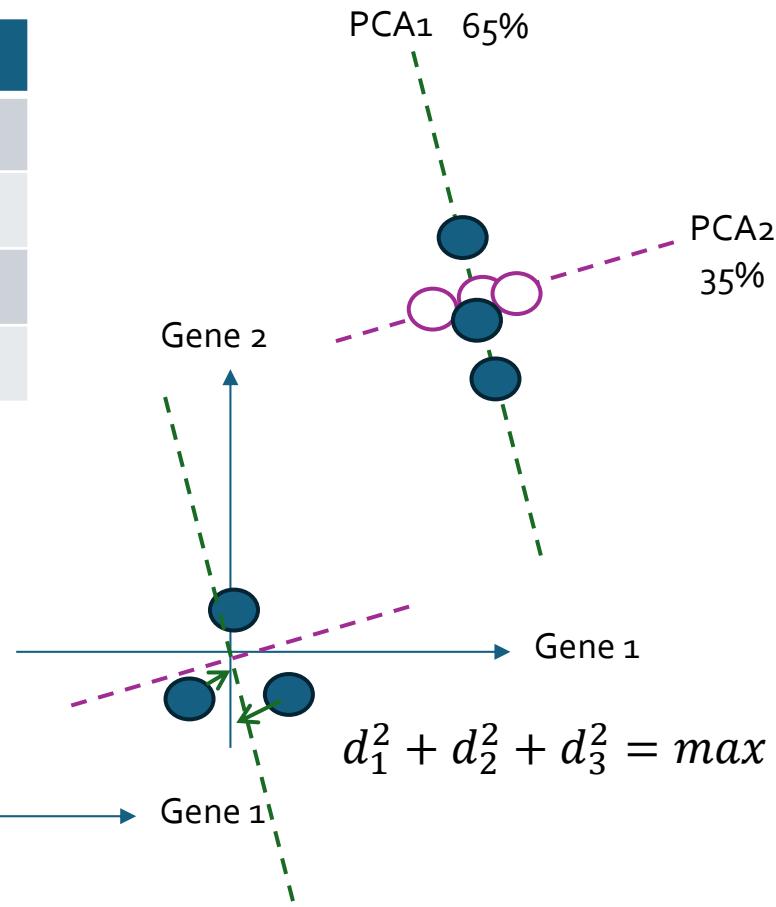
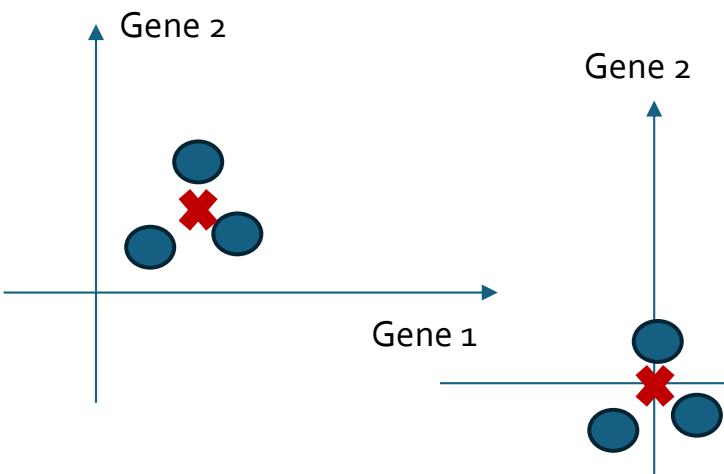
Dichtebasiertes Clustering - Clustering Verfahren



- Definition von Cluster durch Punktdichte (statt Abstand zum Zentrum).
- Unterscheidung in Kernpunkte, Randpunkte und Rauschen.
- Vorteil: Erkennt Cluster beliebiger Form (nicht nur Kugeln).
- Feature: Kann Noise (Rauschen) identifizieren und aussortieren (wichtig bei chaotischen Daten wie CIFAR-10).

PCA

	Gene 1	Gene 2	...
Maus 1	1	2	...
Maus 2	3	4	...
Maus 3	2	3	...
...



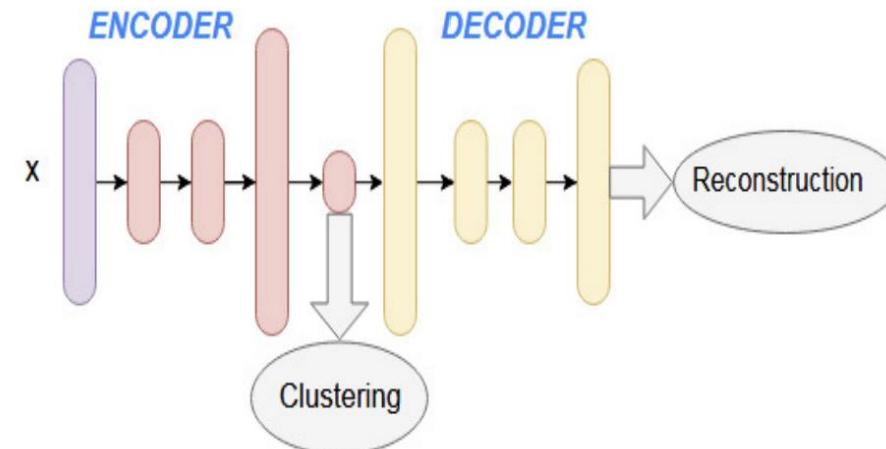
- Mehrdimensionalität schwer im Koordinatensystem darzustellen
- Man nimmt zwei Spalten und analysiert sie
- Man sucht Schwerpunkt der Daten
- Man verschiebt die Punkte (erlaubt, da Relativität nicht verloren geht)
- Man zieht Gerade durch den Ursprung (wie sie liegt, hängt von Abständen ab)
- Man führt die Punkte direkt (im 90°) zur Geraden
- Steigung der Geraden = Verhältnis (-x/y)
- Oft Länge der Steigung = 1 für Eigenvektor und Eigenwert
- Eigenwert (Varianz) beschreibt Einfluss

Autoencoder

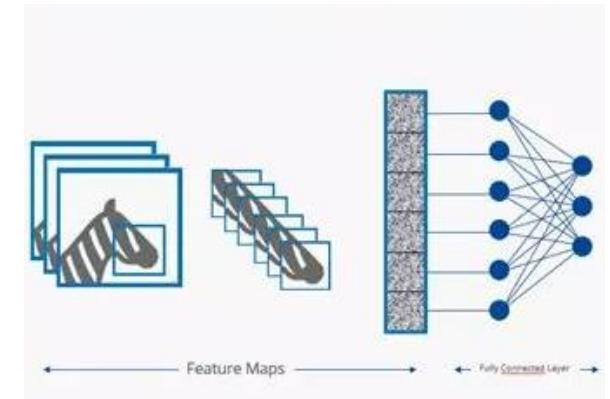
$$\mathbb{R}^D \leftrightarrow \mathbb{R}^d \text{ (ideal)}$$

- Statt zu Projizieren komprimiert der Encoder die Daten durch Aktivierungsfunktion
- Zwischenraum für Datenverarbeitung
- Verliert Interpretierbarkeit
- Decoder zum Prüfen der komprimierten Darstellung

$$z = h(W \cdot x + b)$$

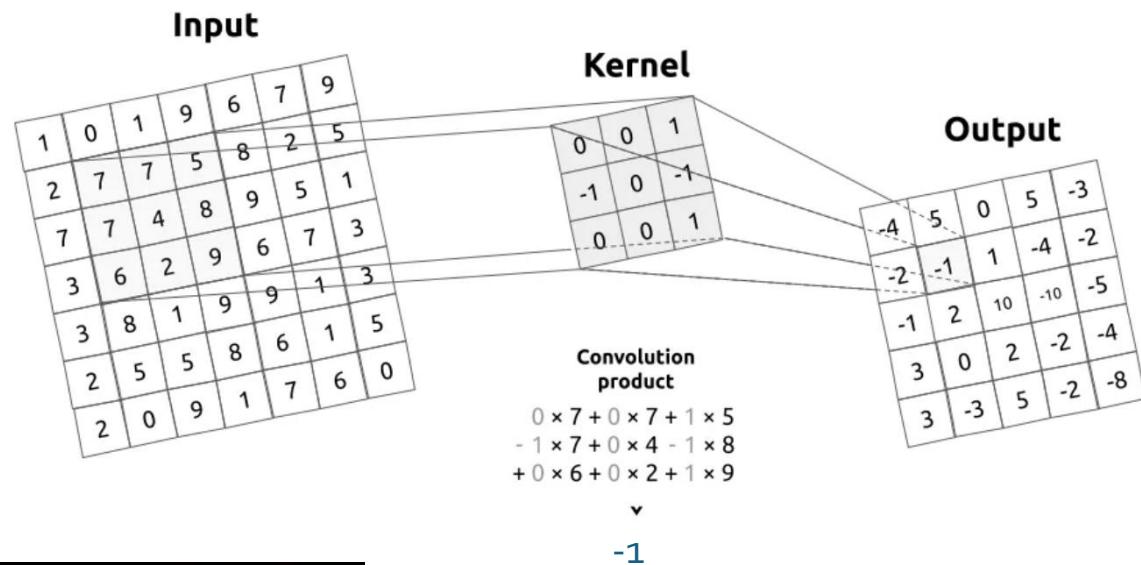


- Linearer Autoencoder (LAE) mit linearer Aktivierungsfunktion (vollständig verbundene Schicht) für MNIST
- Convolutional Autoencoder (CAE) mit Faltungsschichten für CIFAR10



Convolution (Faltung)

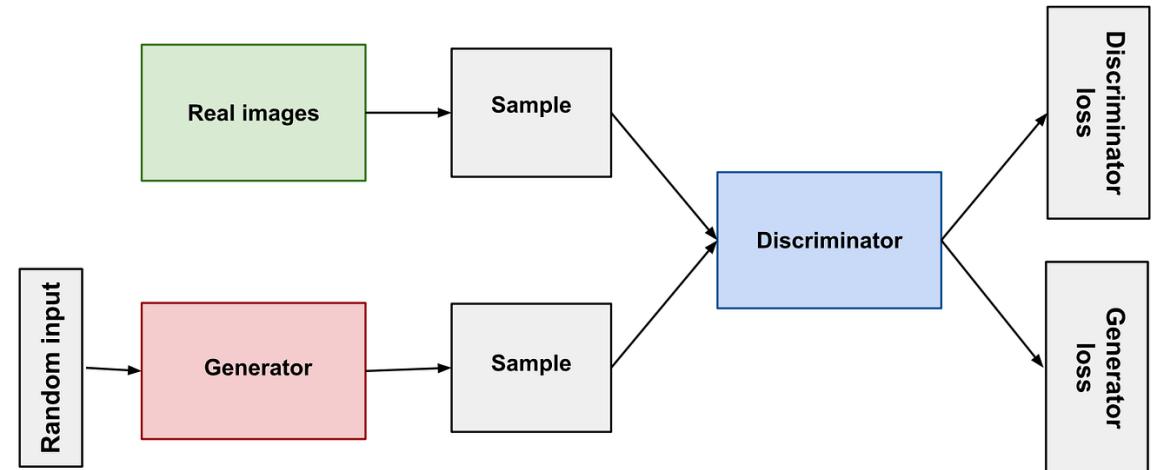
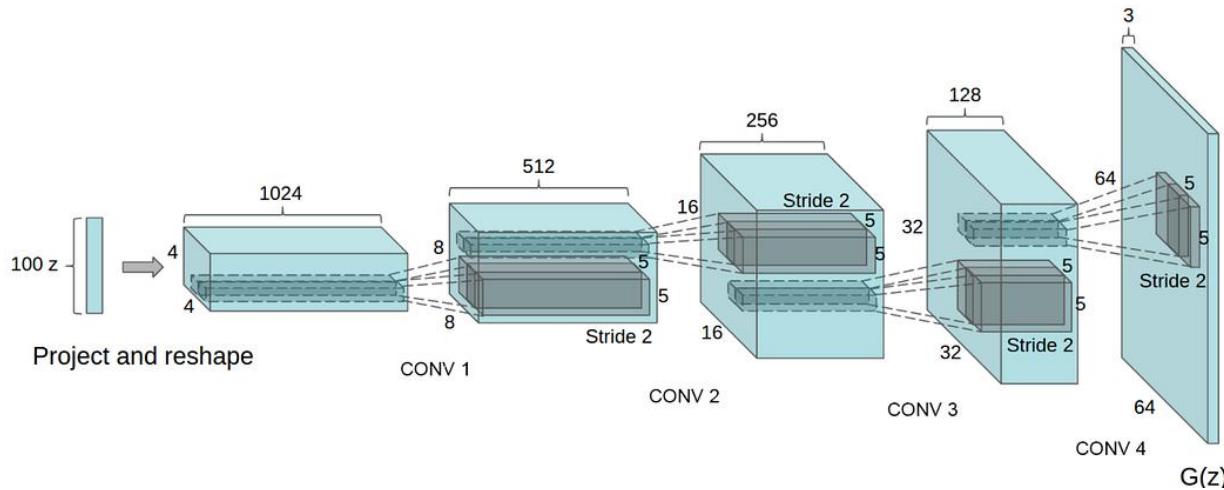
- Input mit Filter multipliziert
- Output nennt man „Feature Map“
- 7×7 und 3×3 ergibt 5×5 Feature Map
- $OH = IH - FH + 1$
- $OB = IB - FB + 1$



Beispiel: Darstellung von Figuren

DCGAN (generativ)

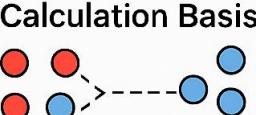
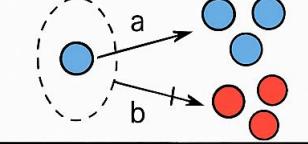
- DCGAN ist ein GAN mit veränderter Schichtstruktur für die Implementierung des Generators G und Diskriminators

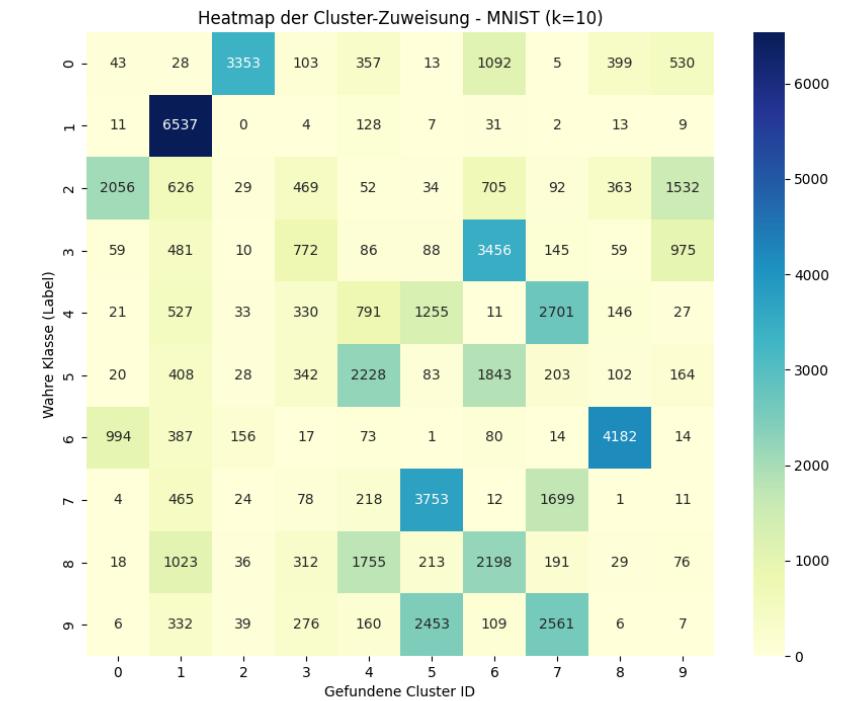
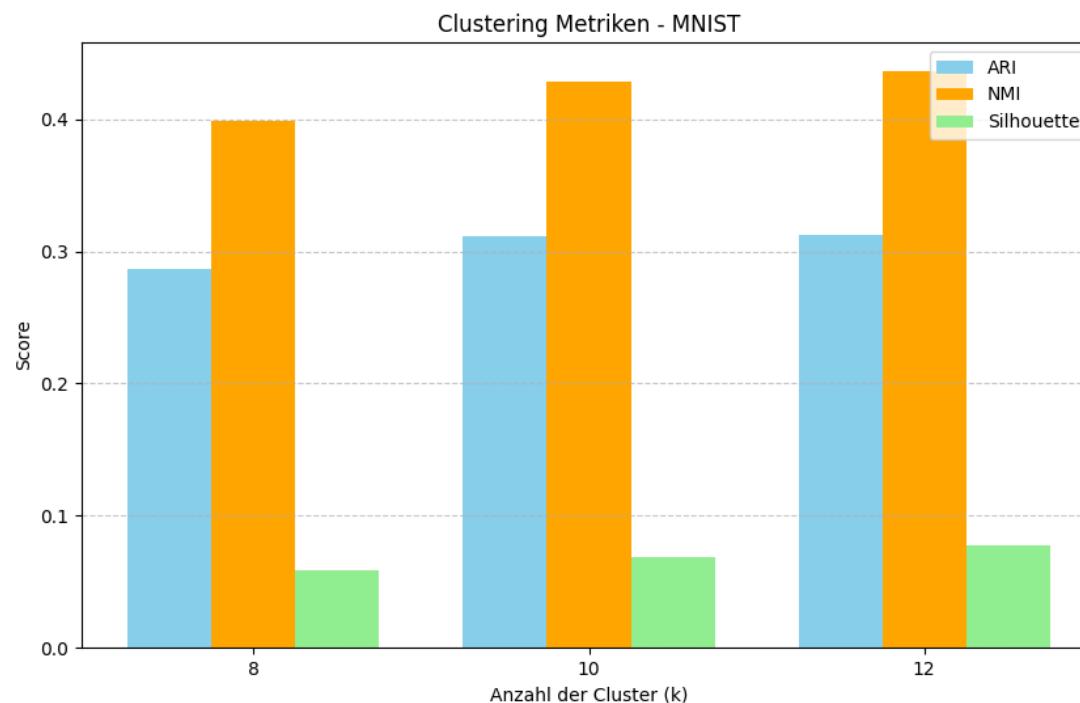


- Generator generiert Fake-Daten
- Diskriminator erkennt Daten
- Fake- und Real-Daten werden gemischt
- Entweder täuscht Generator oder Diskriminator erkennt (nicht beides!)

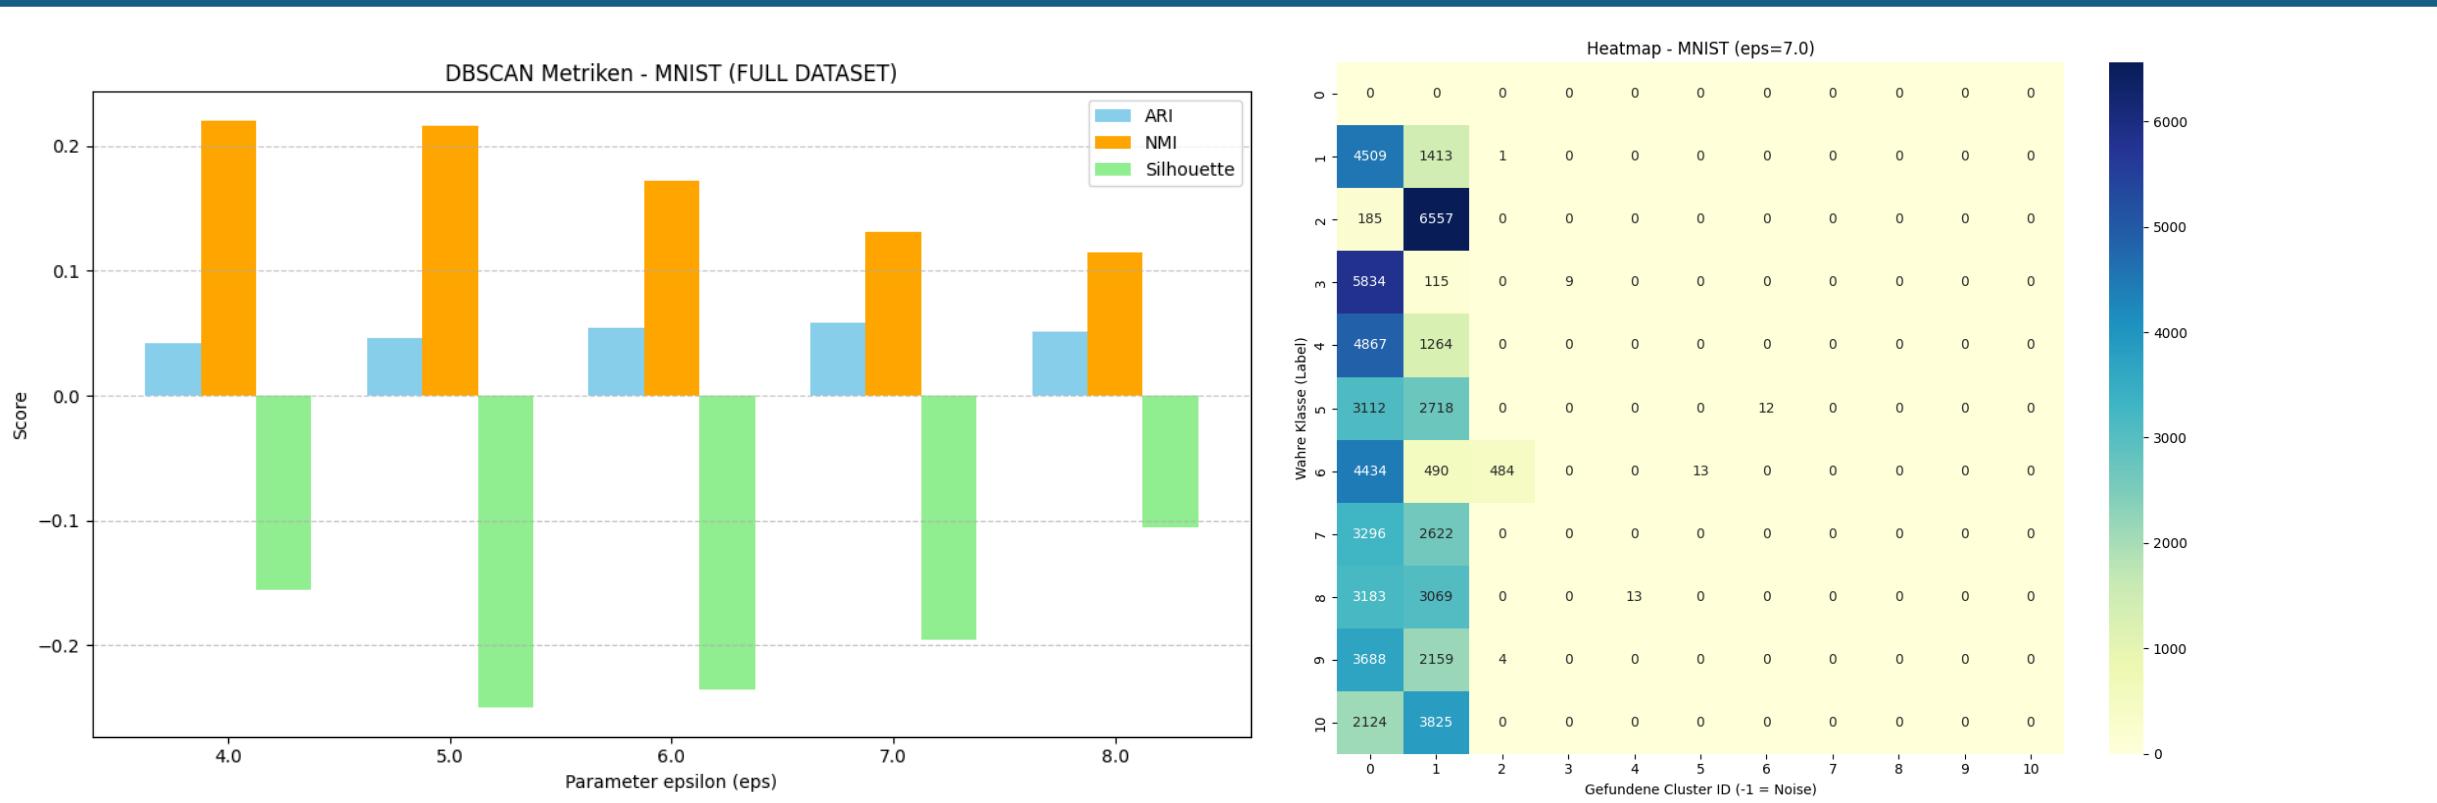
Metriken (Maß)

- ARI – Übereinstimmung zwischen zwei Cluster
- NMI – informationsbasierte Ähnlichkeit
- Silhouette score – Distanzvergleich: eigener Cluster vs. nächster

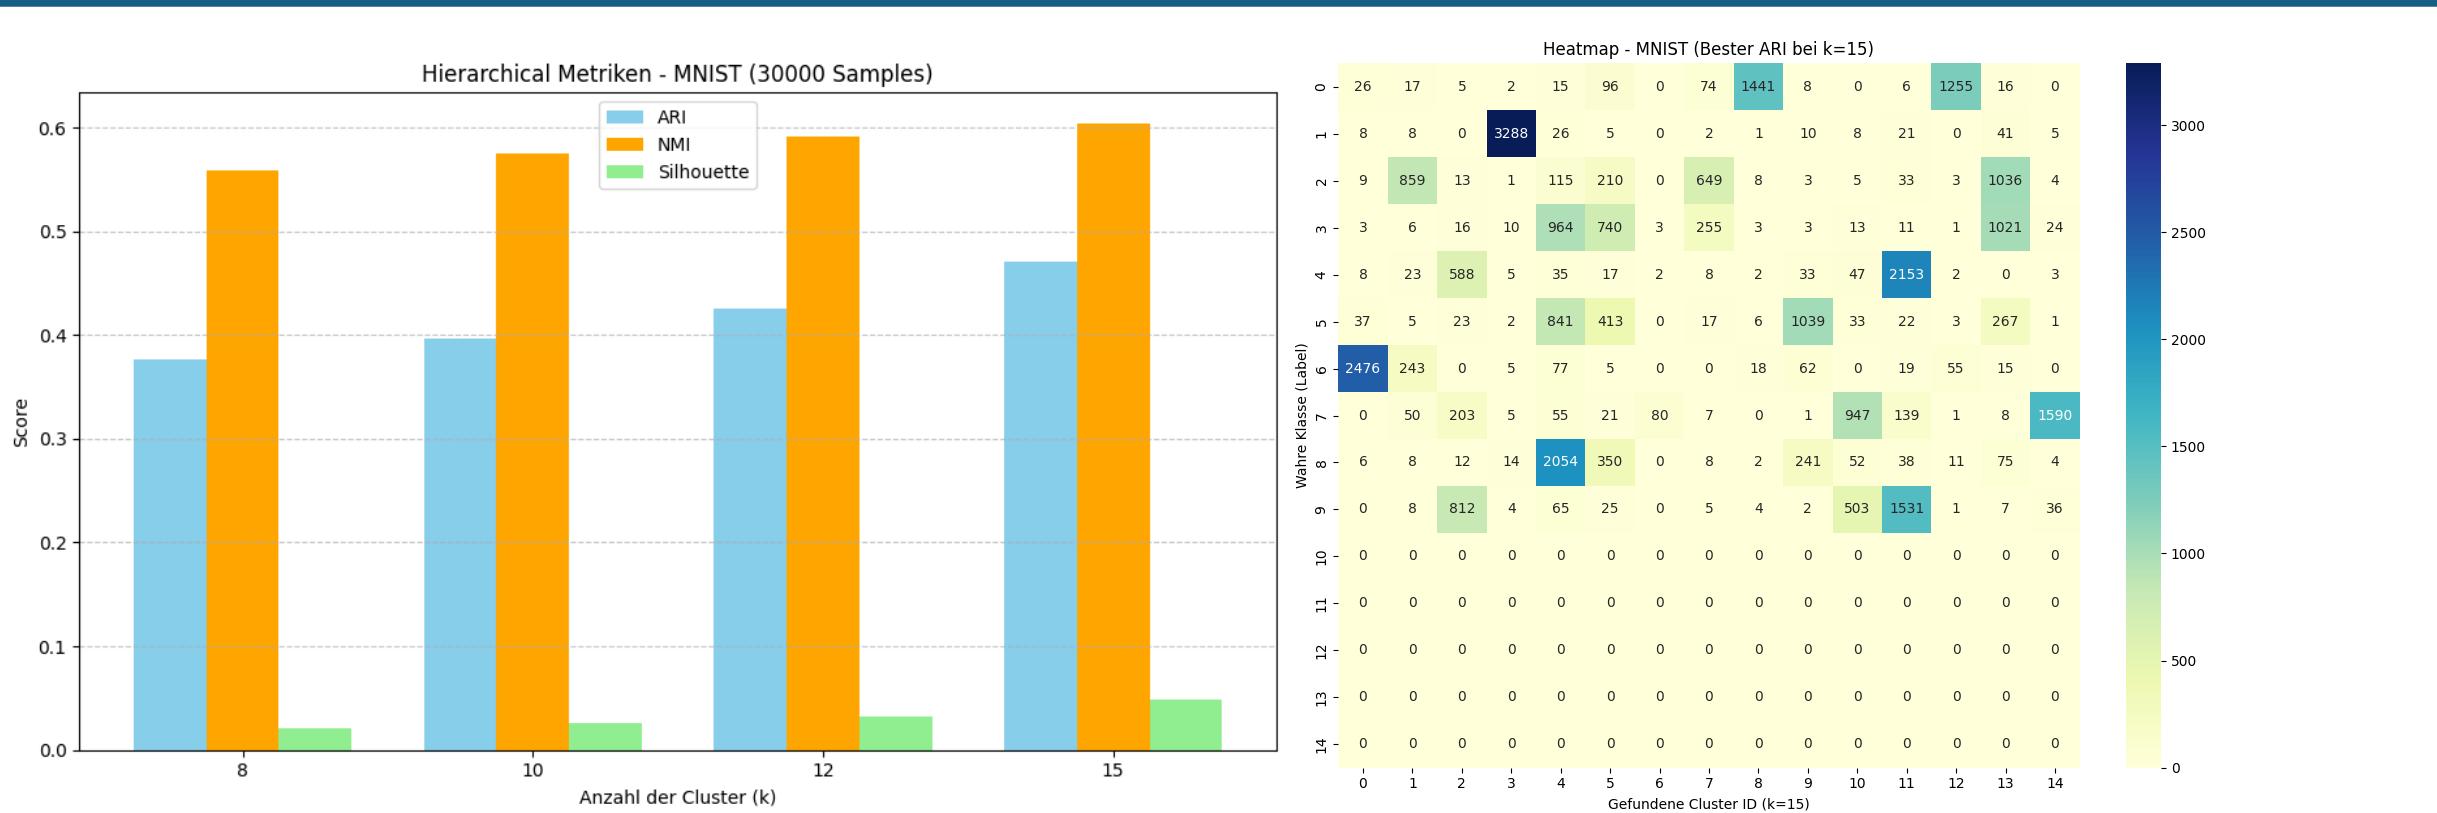
ARI	NMI	Silhouette
Agreement between two clusterings	Information-based similarity	Cluster structure quality
Range 	Range 	Range 
Calculation Basis  $I(U;V)$		
Interpretation 1 = perfect 0 = random <0 = worse than random	Interpretation 1 = perfect 0 = no shared information	Interpretation 1 = well placed 0 = on boundary <0 = misassigned



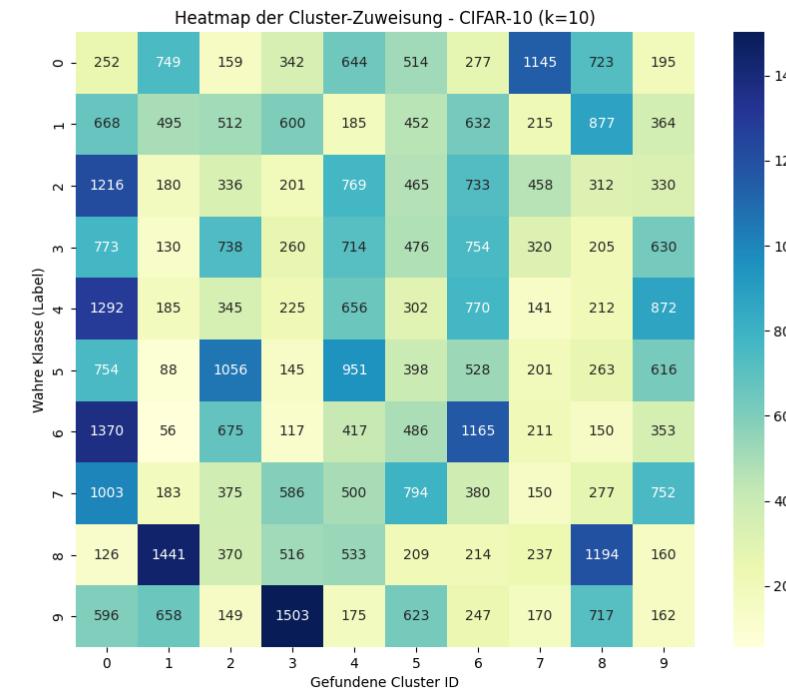
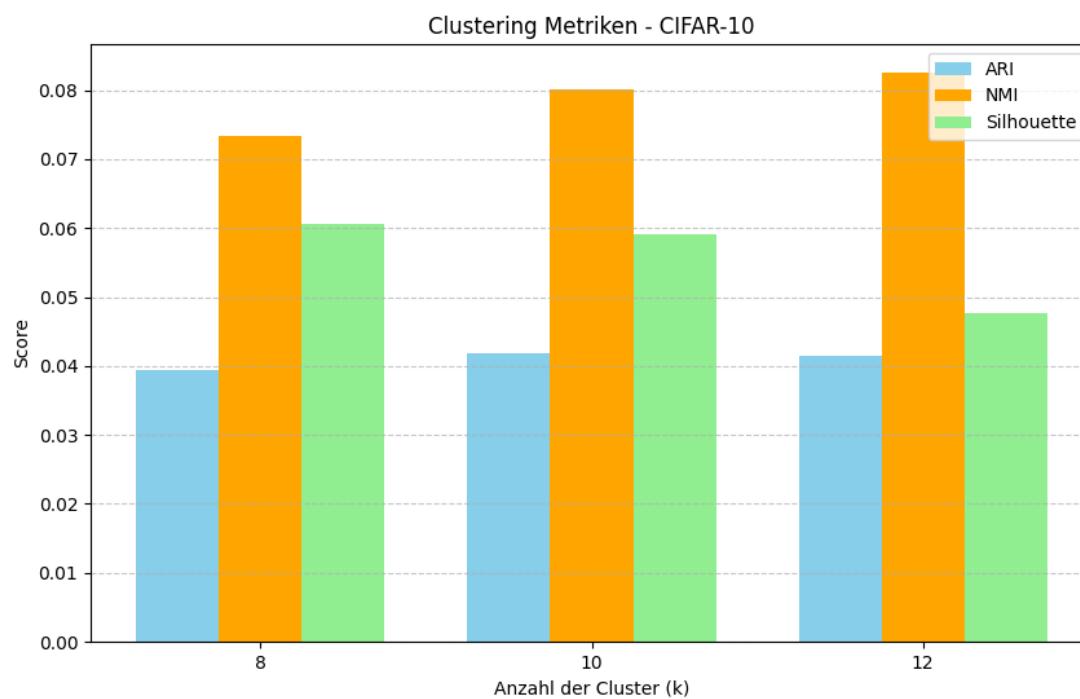
KMEANS BASELINE MIT PCA (MNIST)



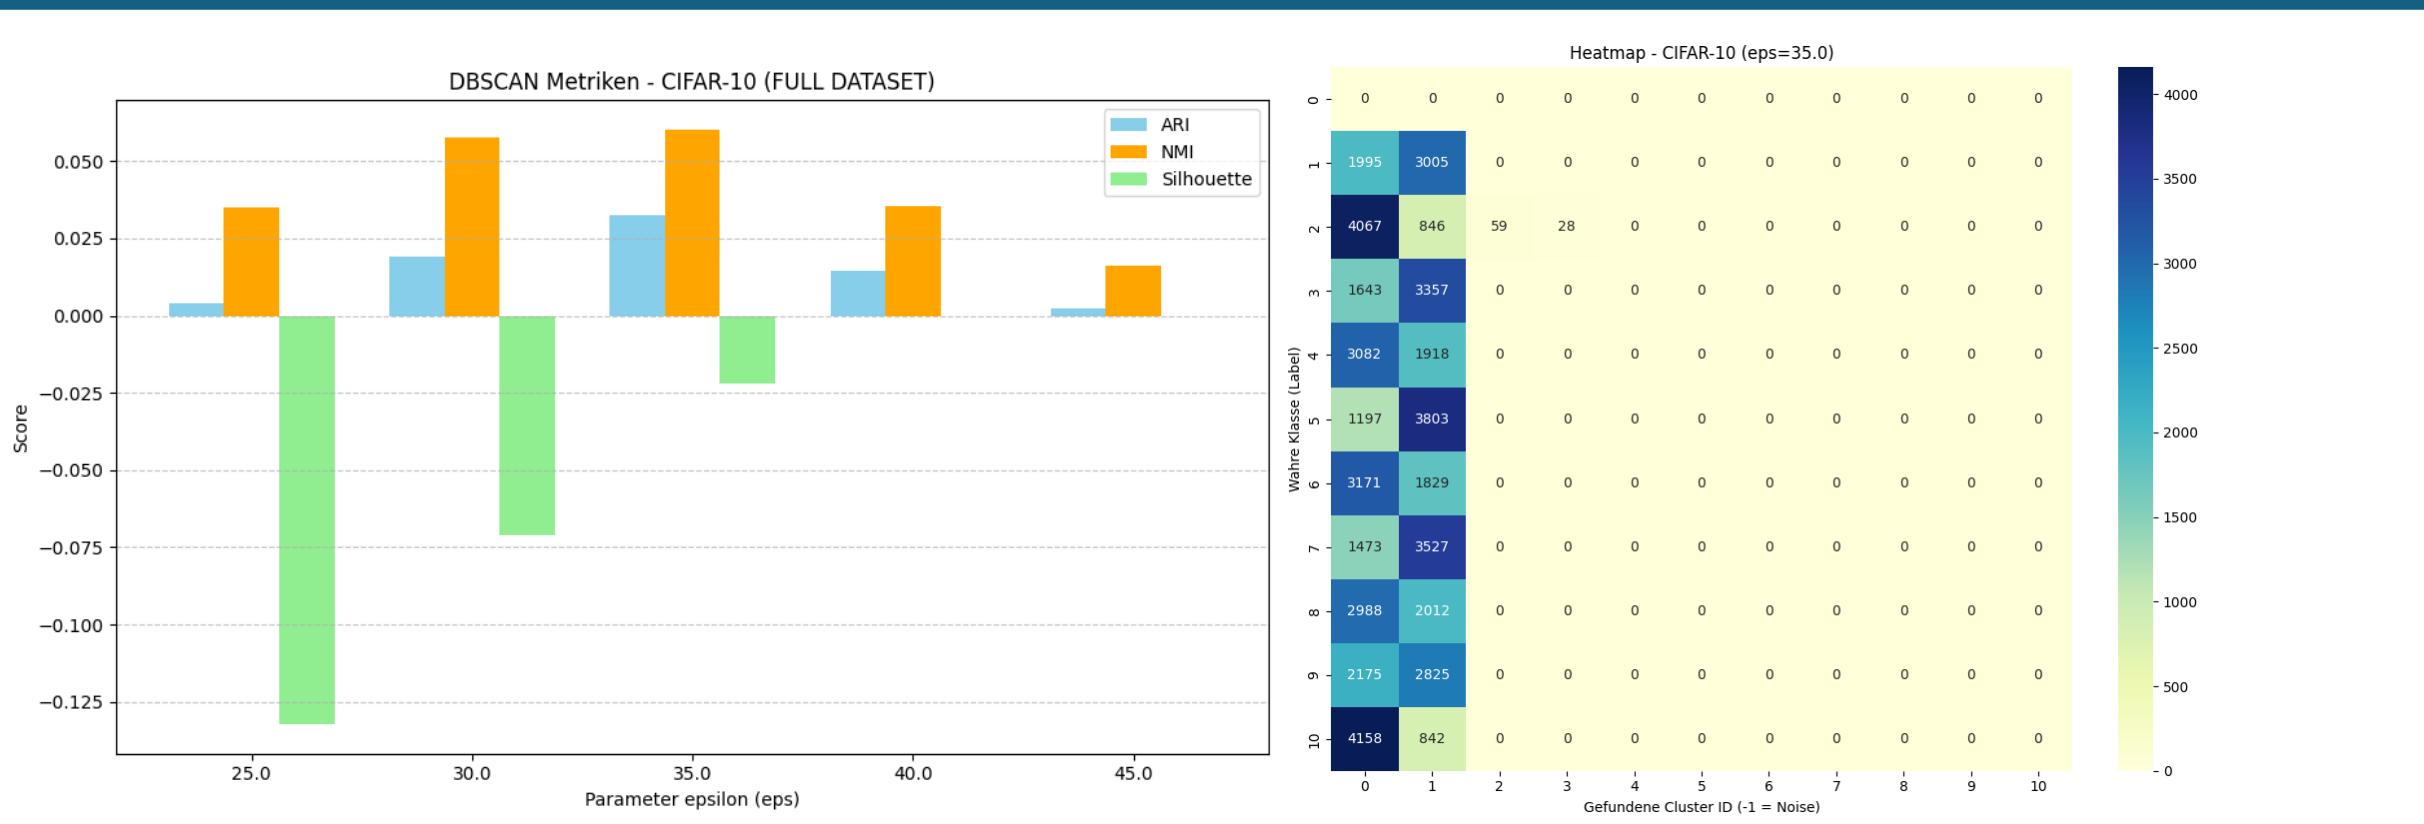
DBSCAN BASELINE MIT PCA (MNIST)



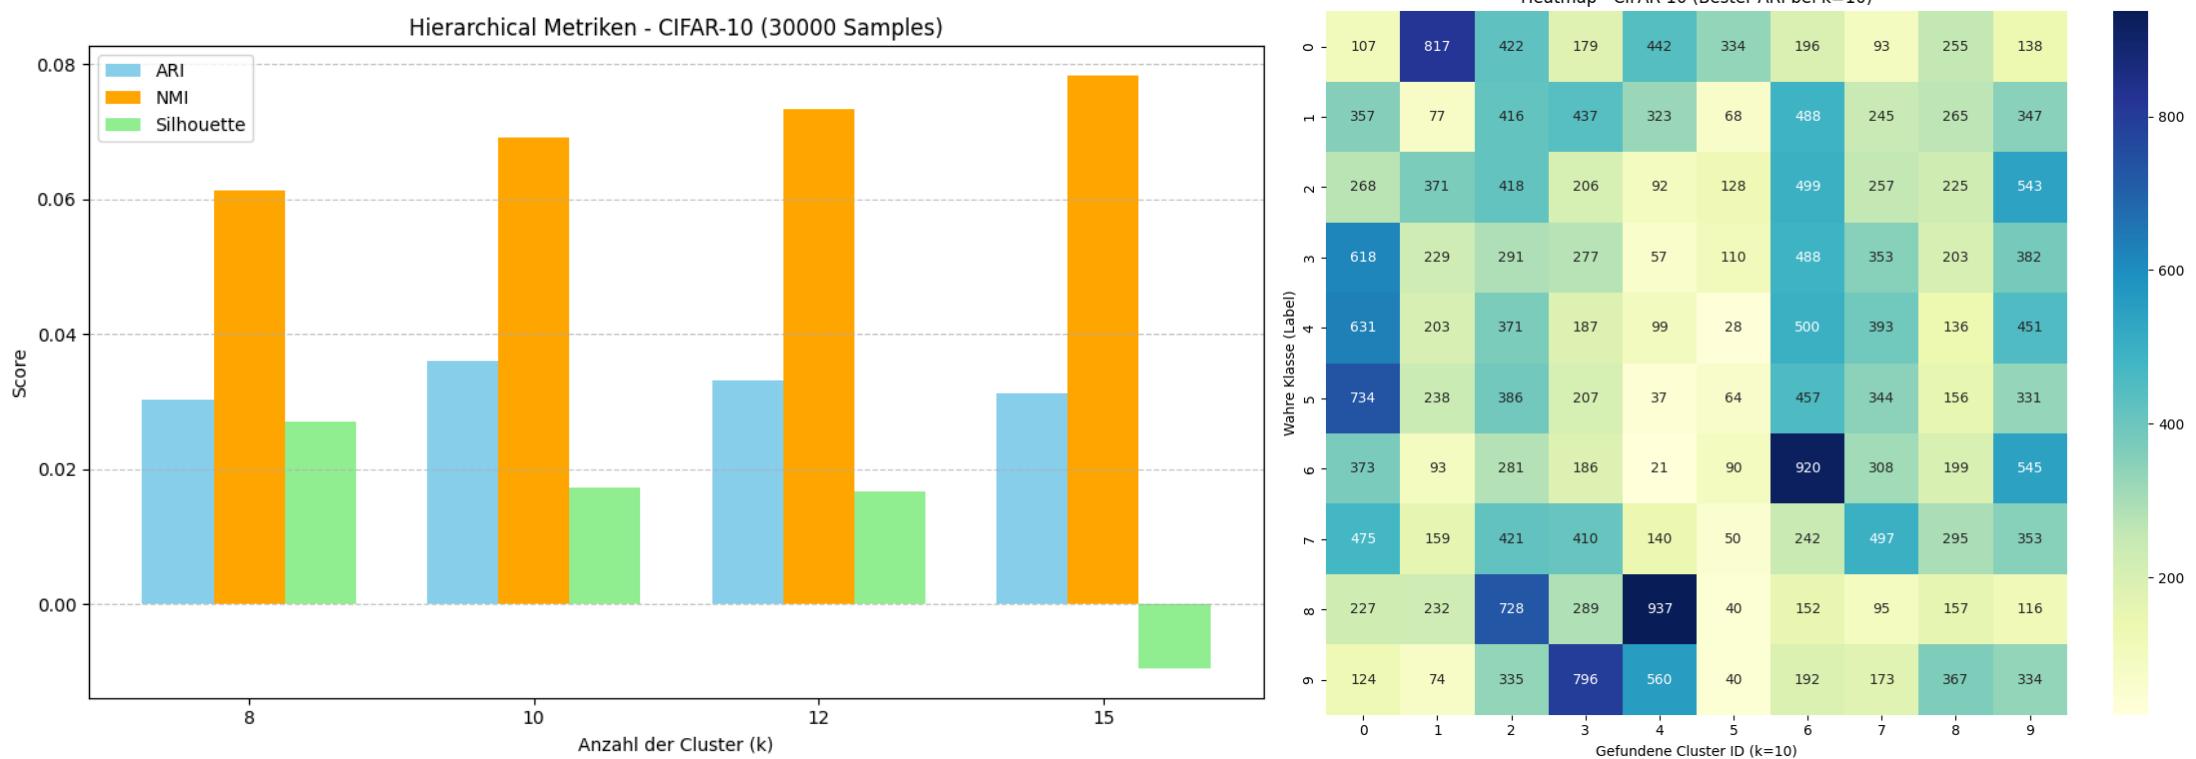
HIERARCHISCHES BASELINE MIT PCA (MNIST)



KMEANS BASELINE MIT PCA (CIFAR-10)

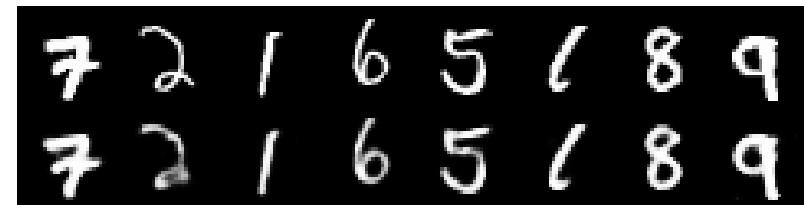
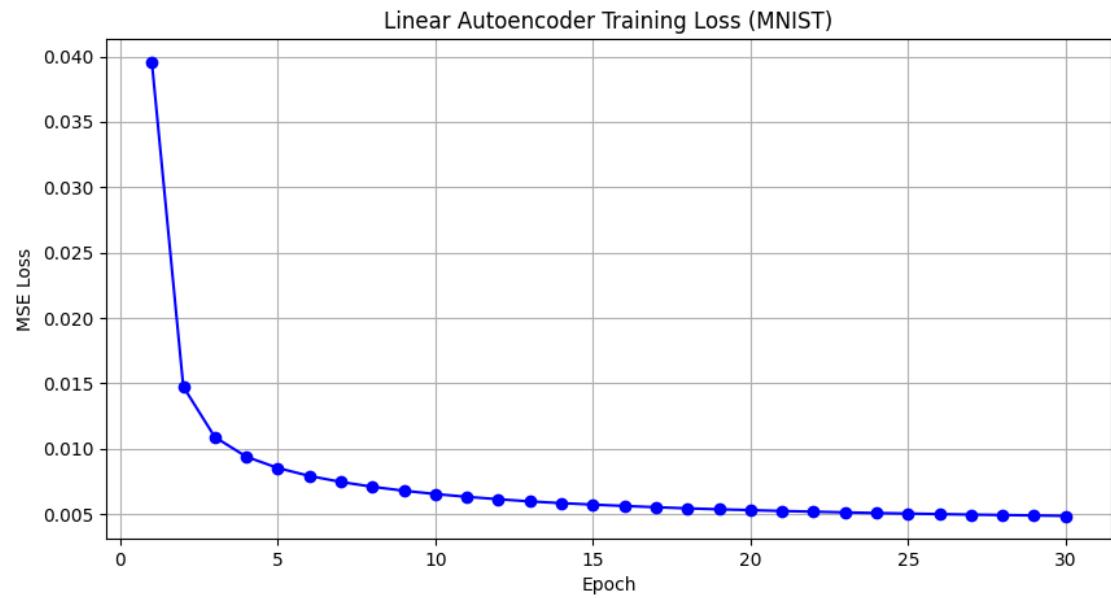


DBSCAN BASELINE MIT PCA (CIFAR-10)

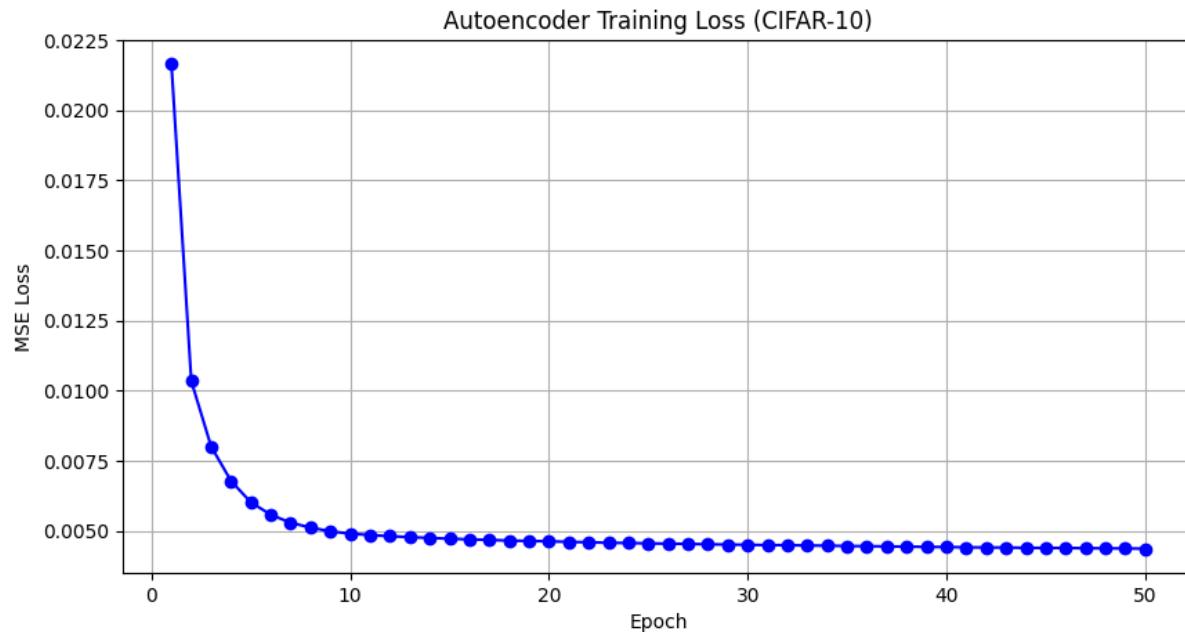


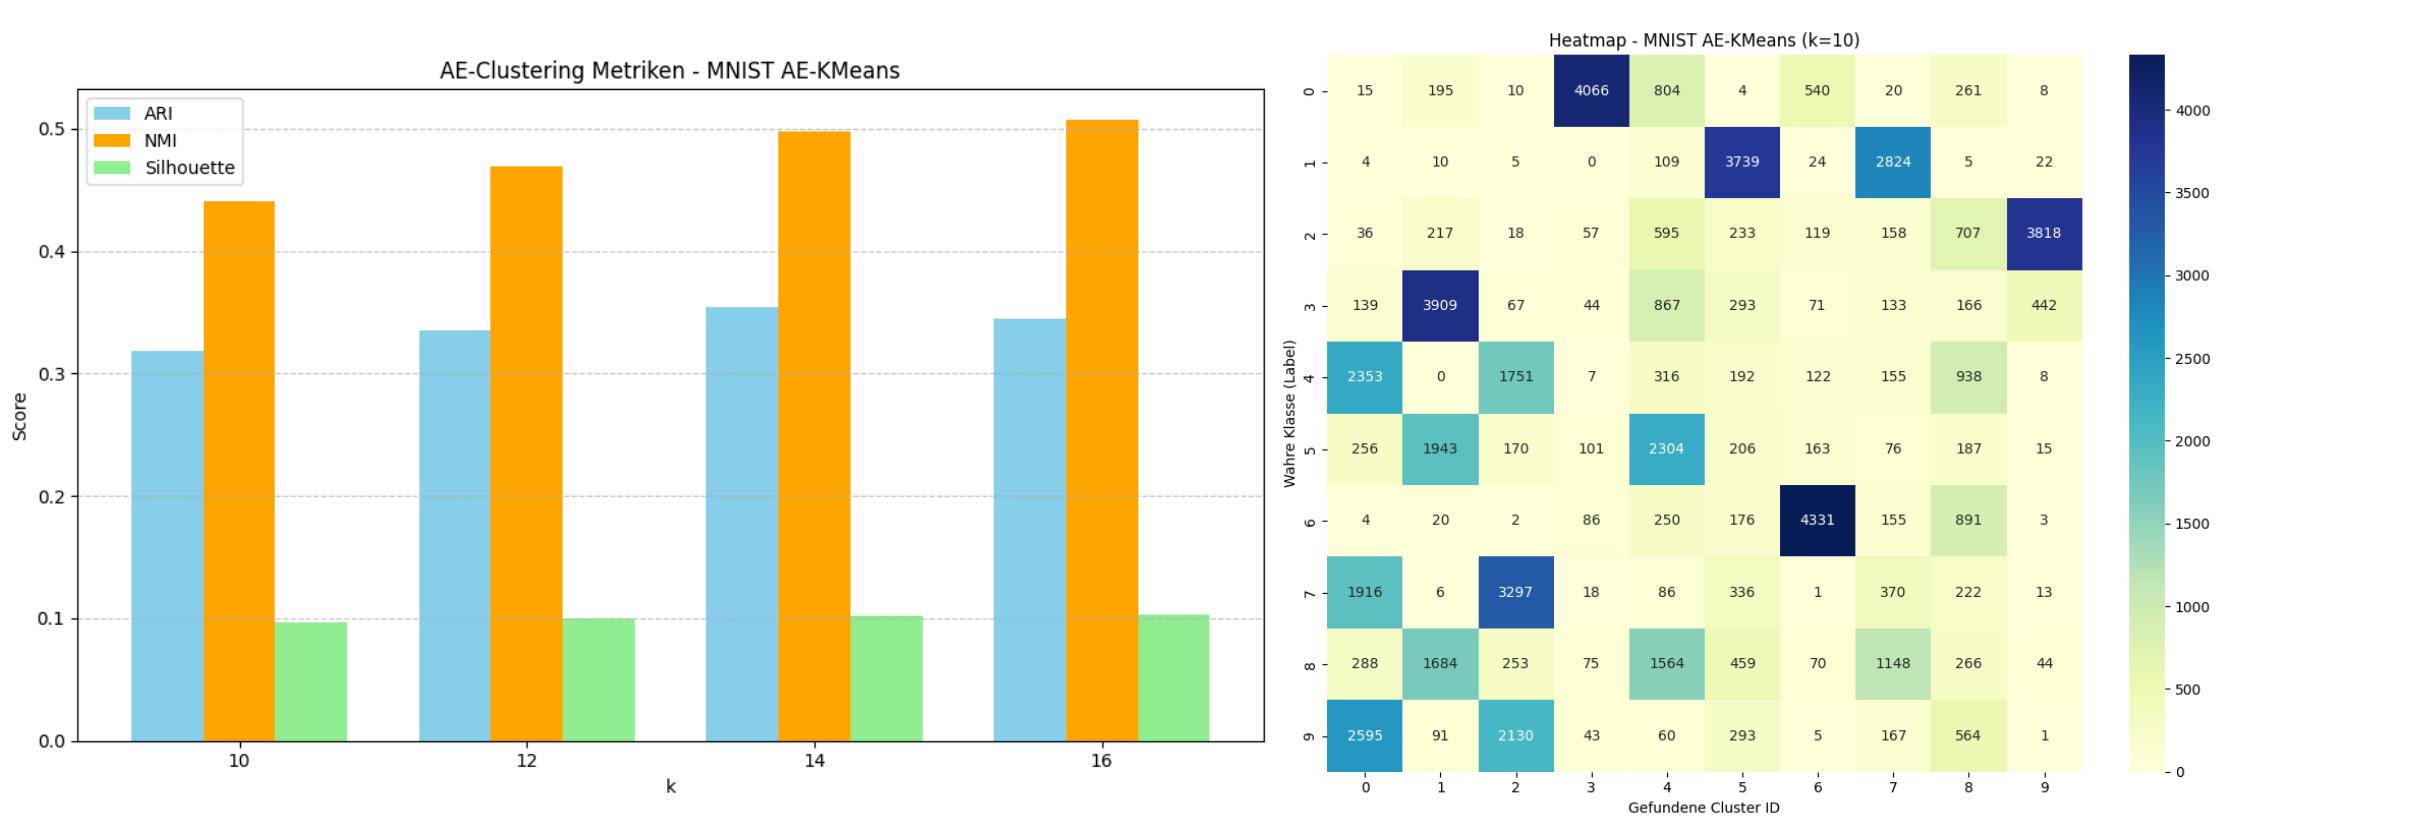
HIERARCHISCHES BASELINE MIT PCA (CIFAR-10)

Linear Autoencoder Training

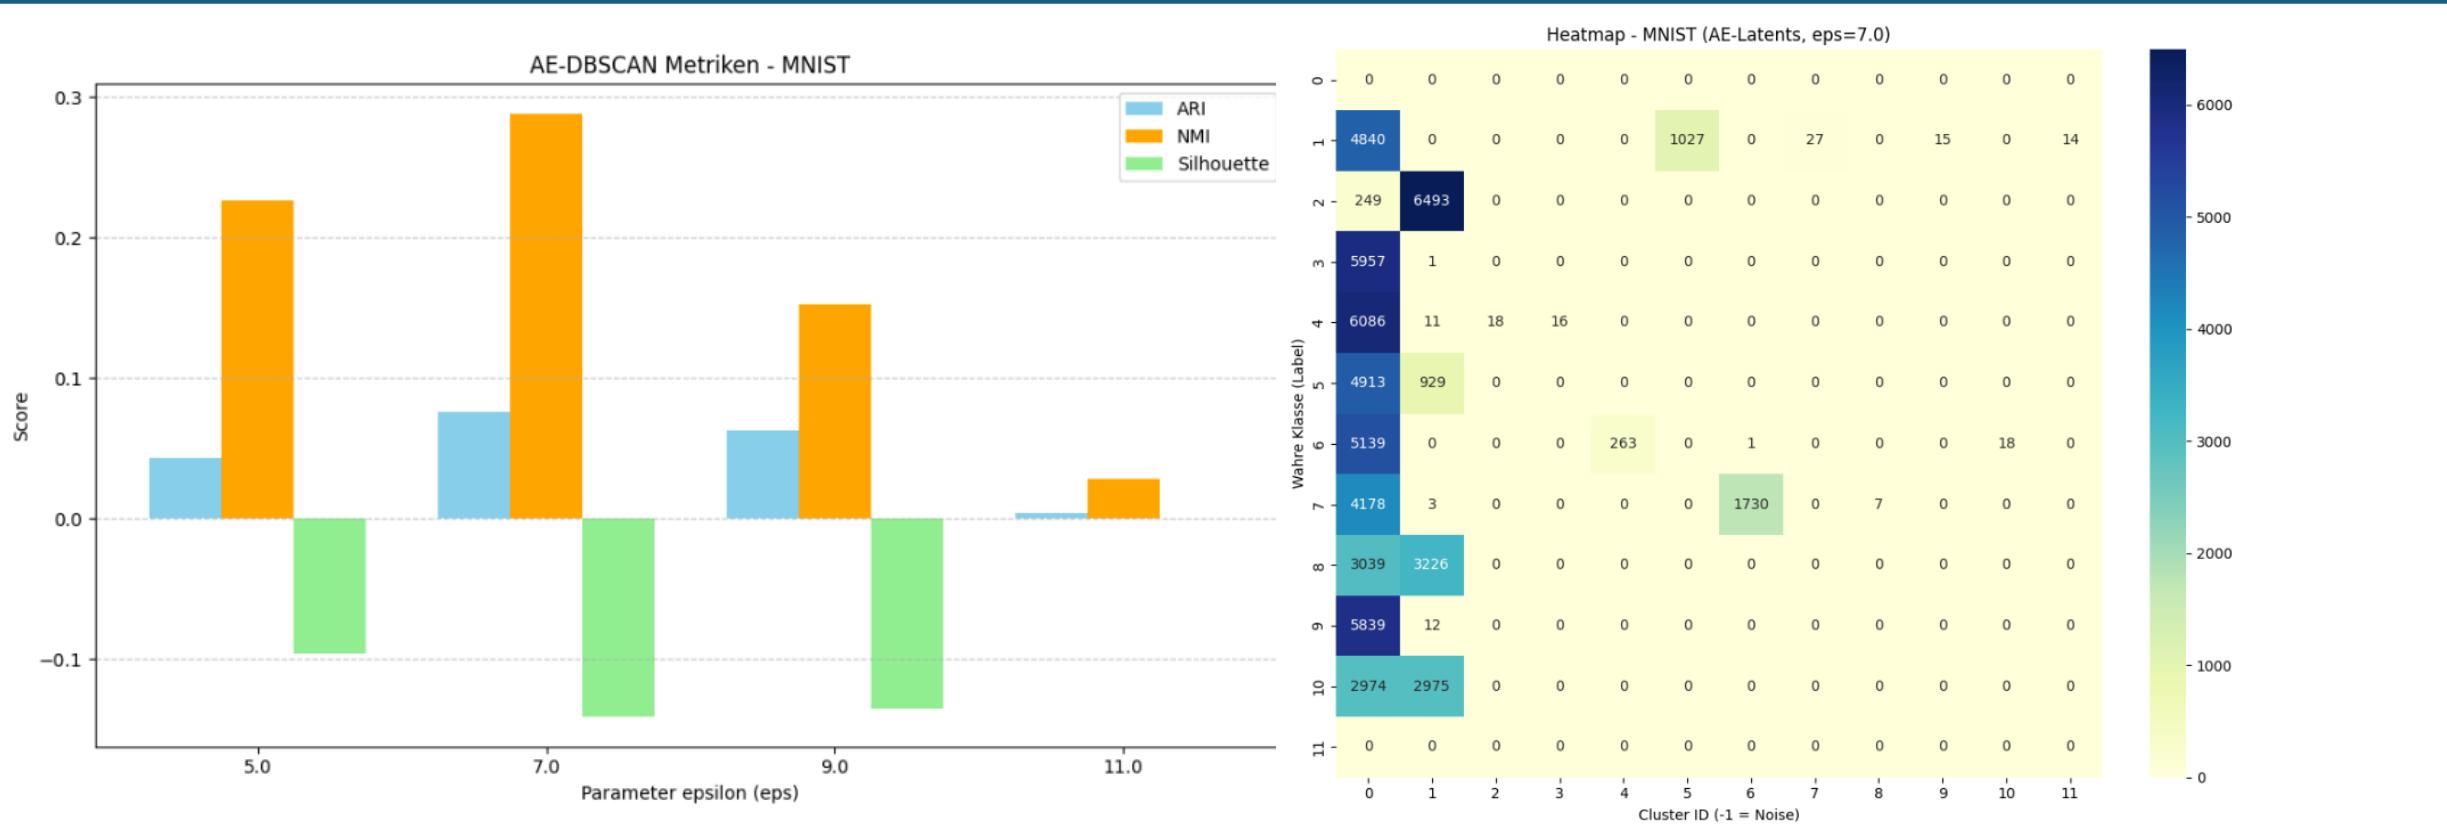


Convolutional Autoencoder Training

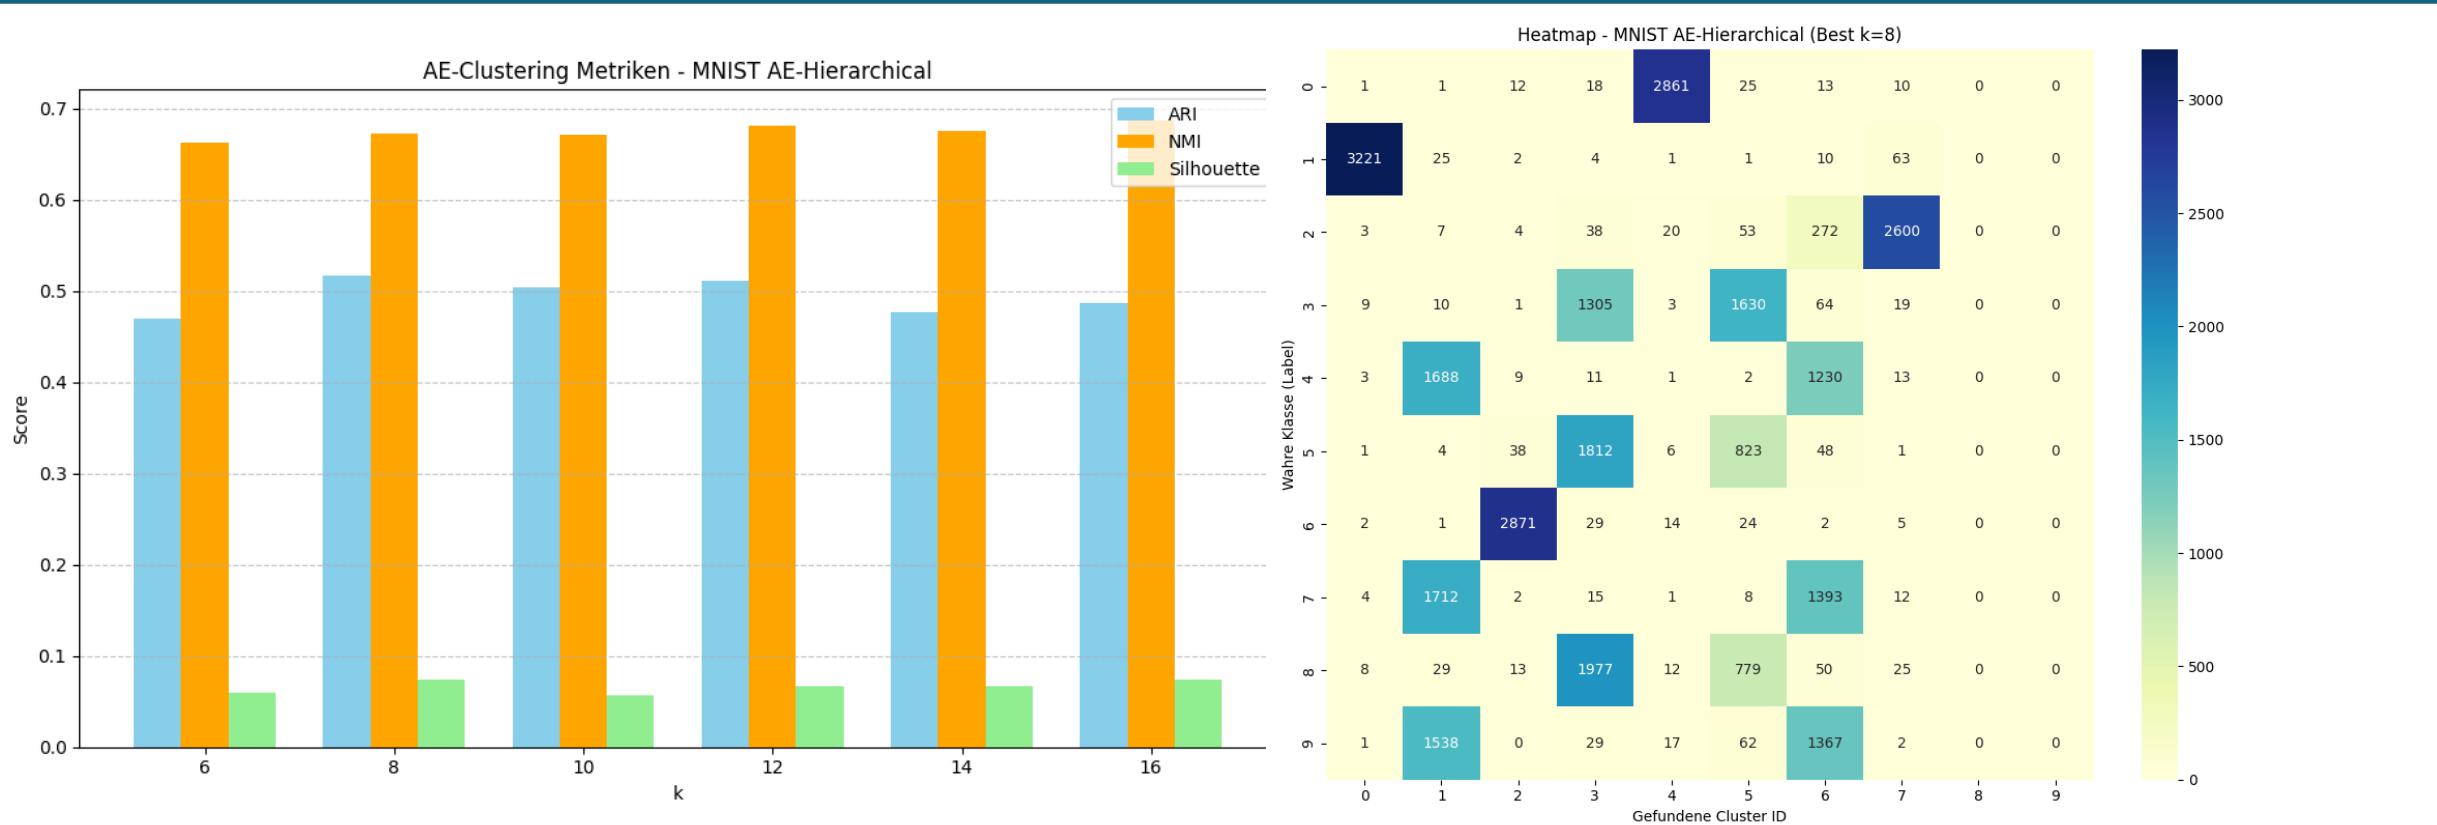




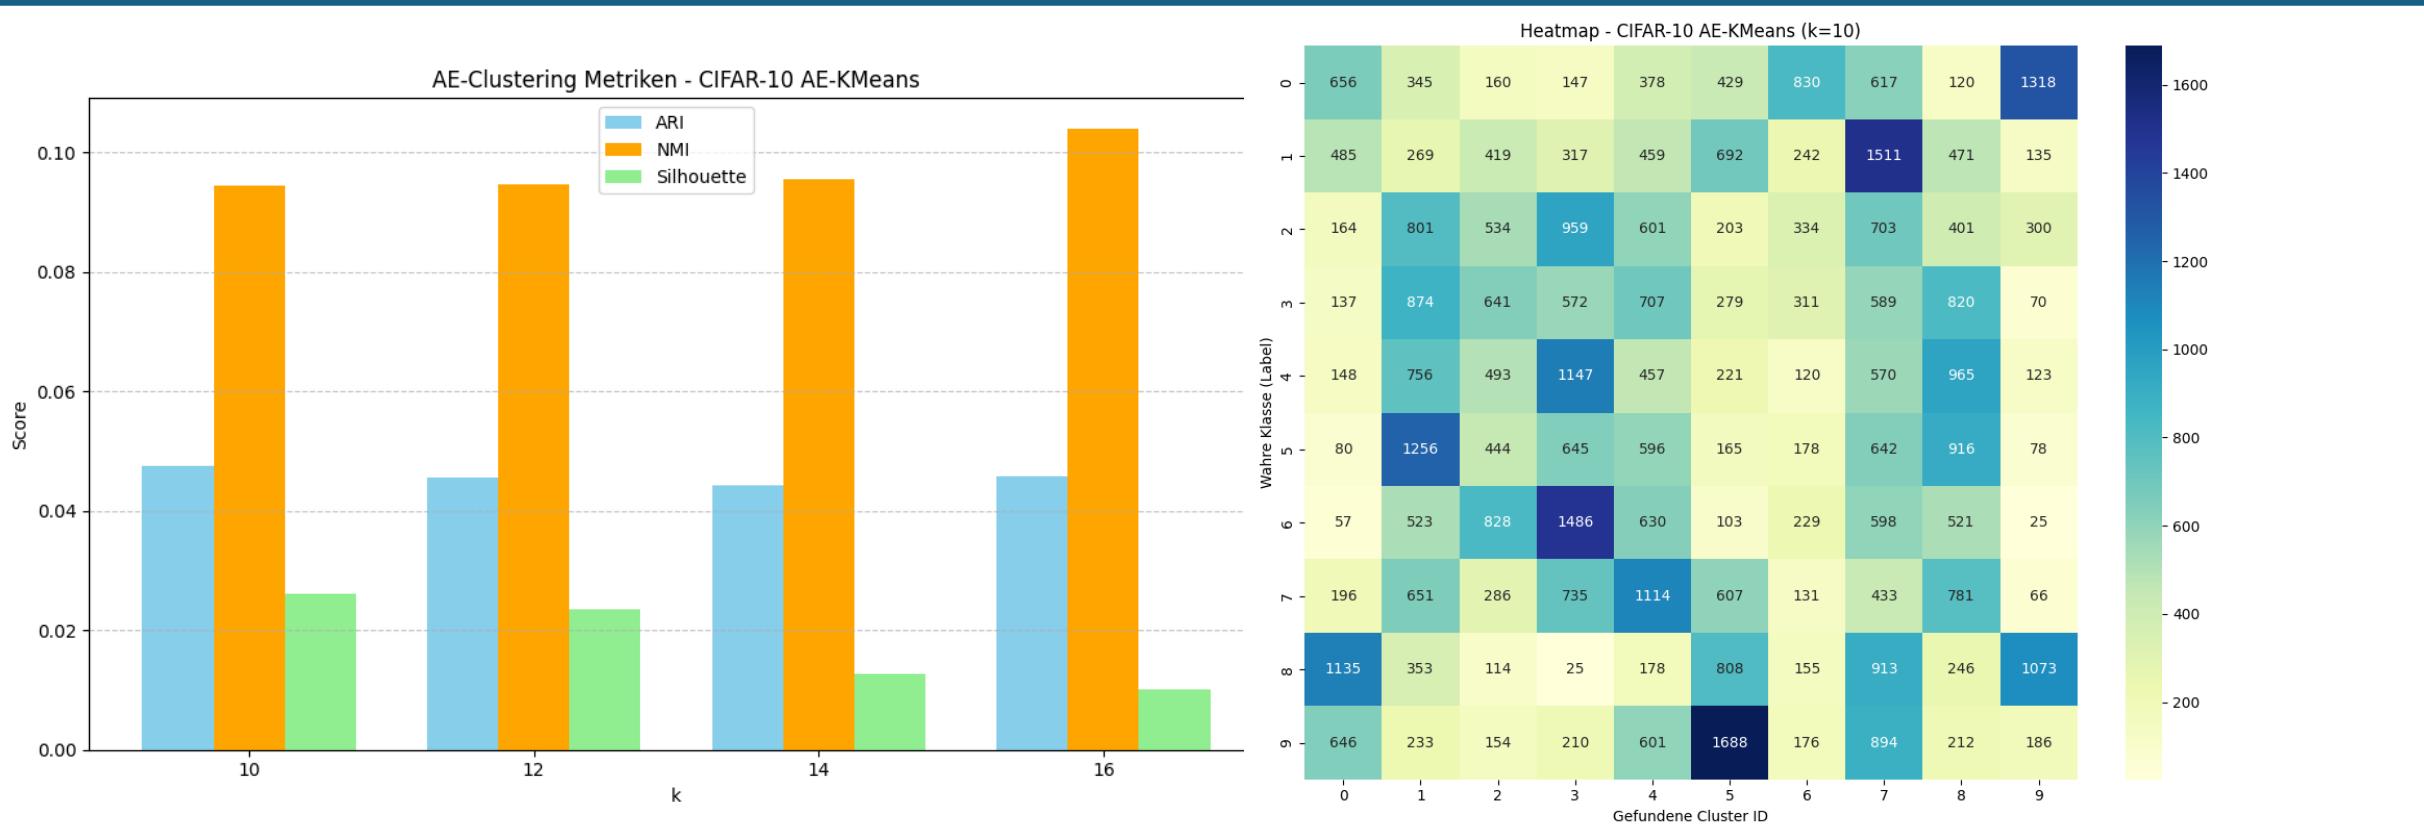
KMEANS AUTOENCODER (MNIST)



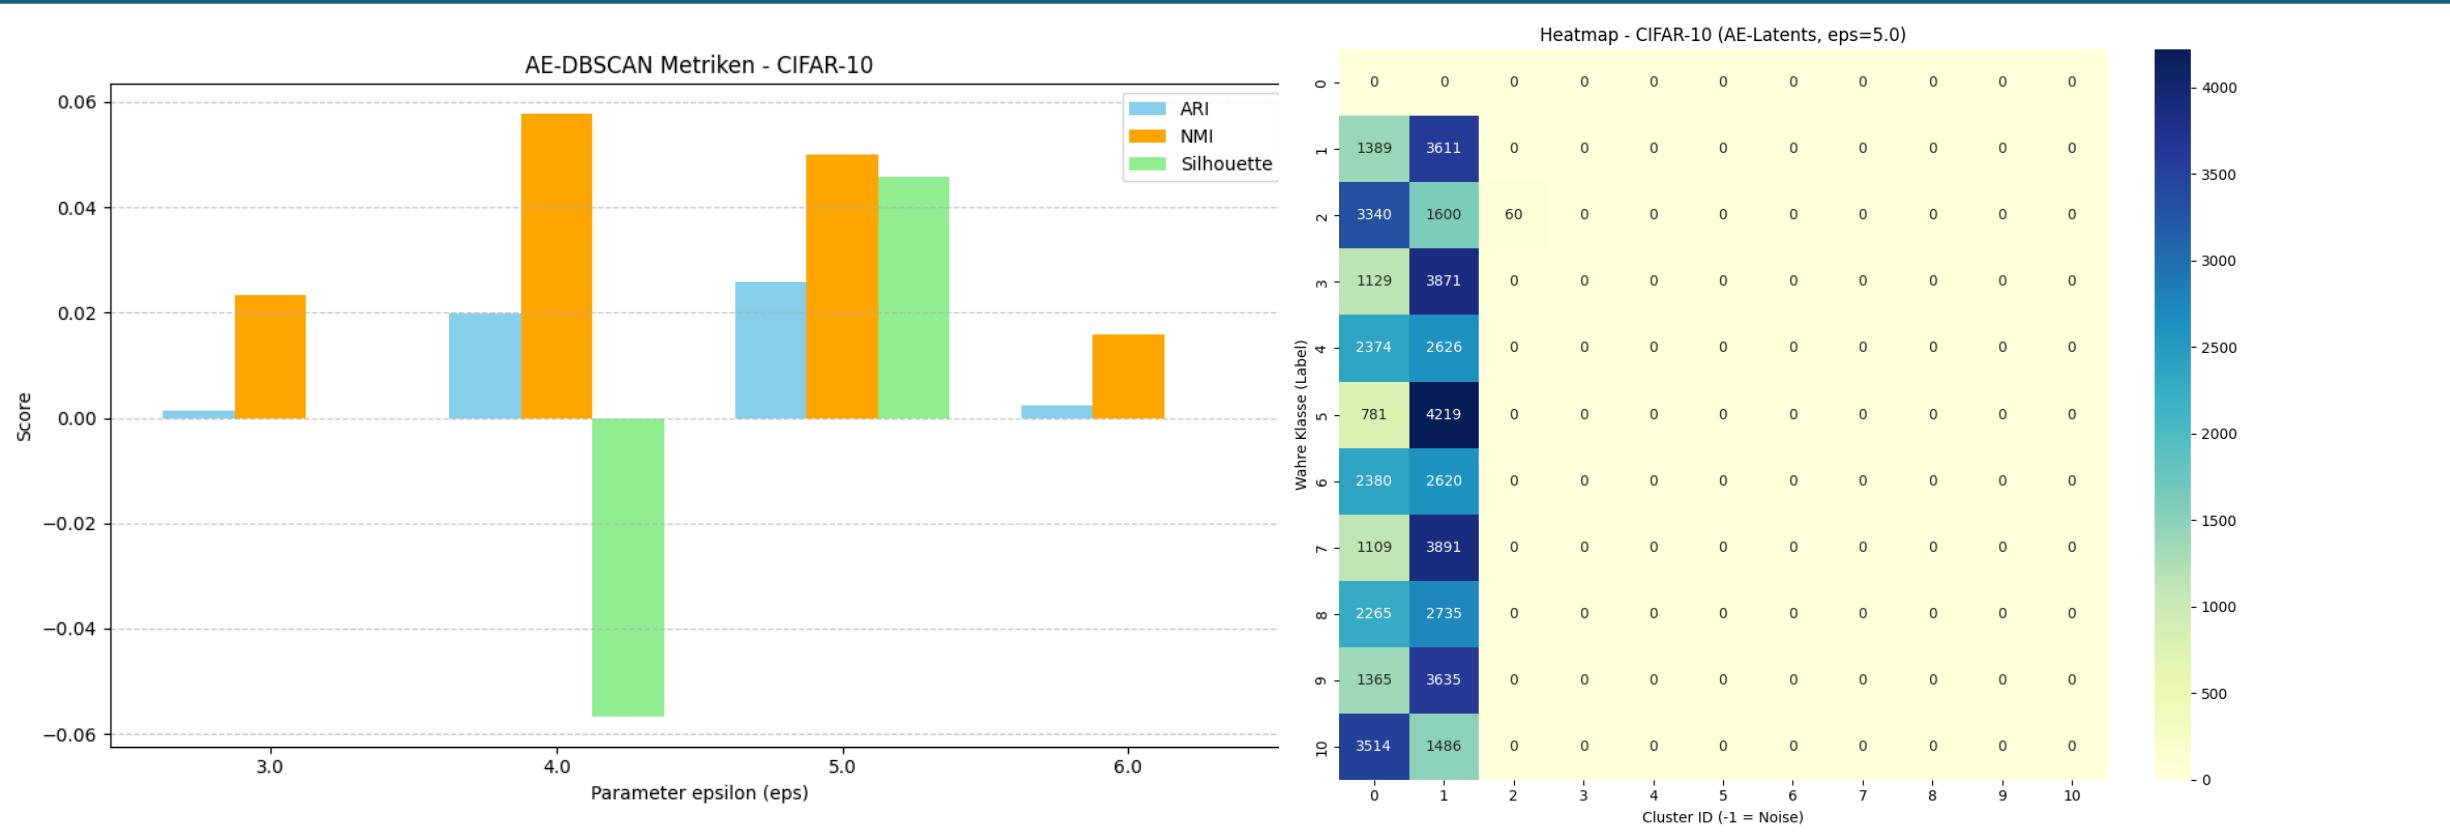
DBSCAN AUTOENCODER (MNIST)



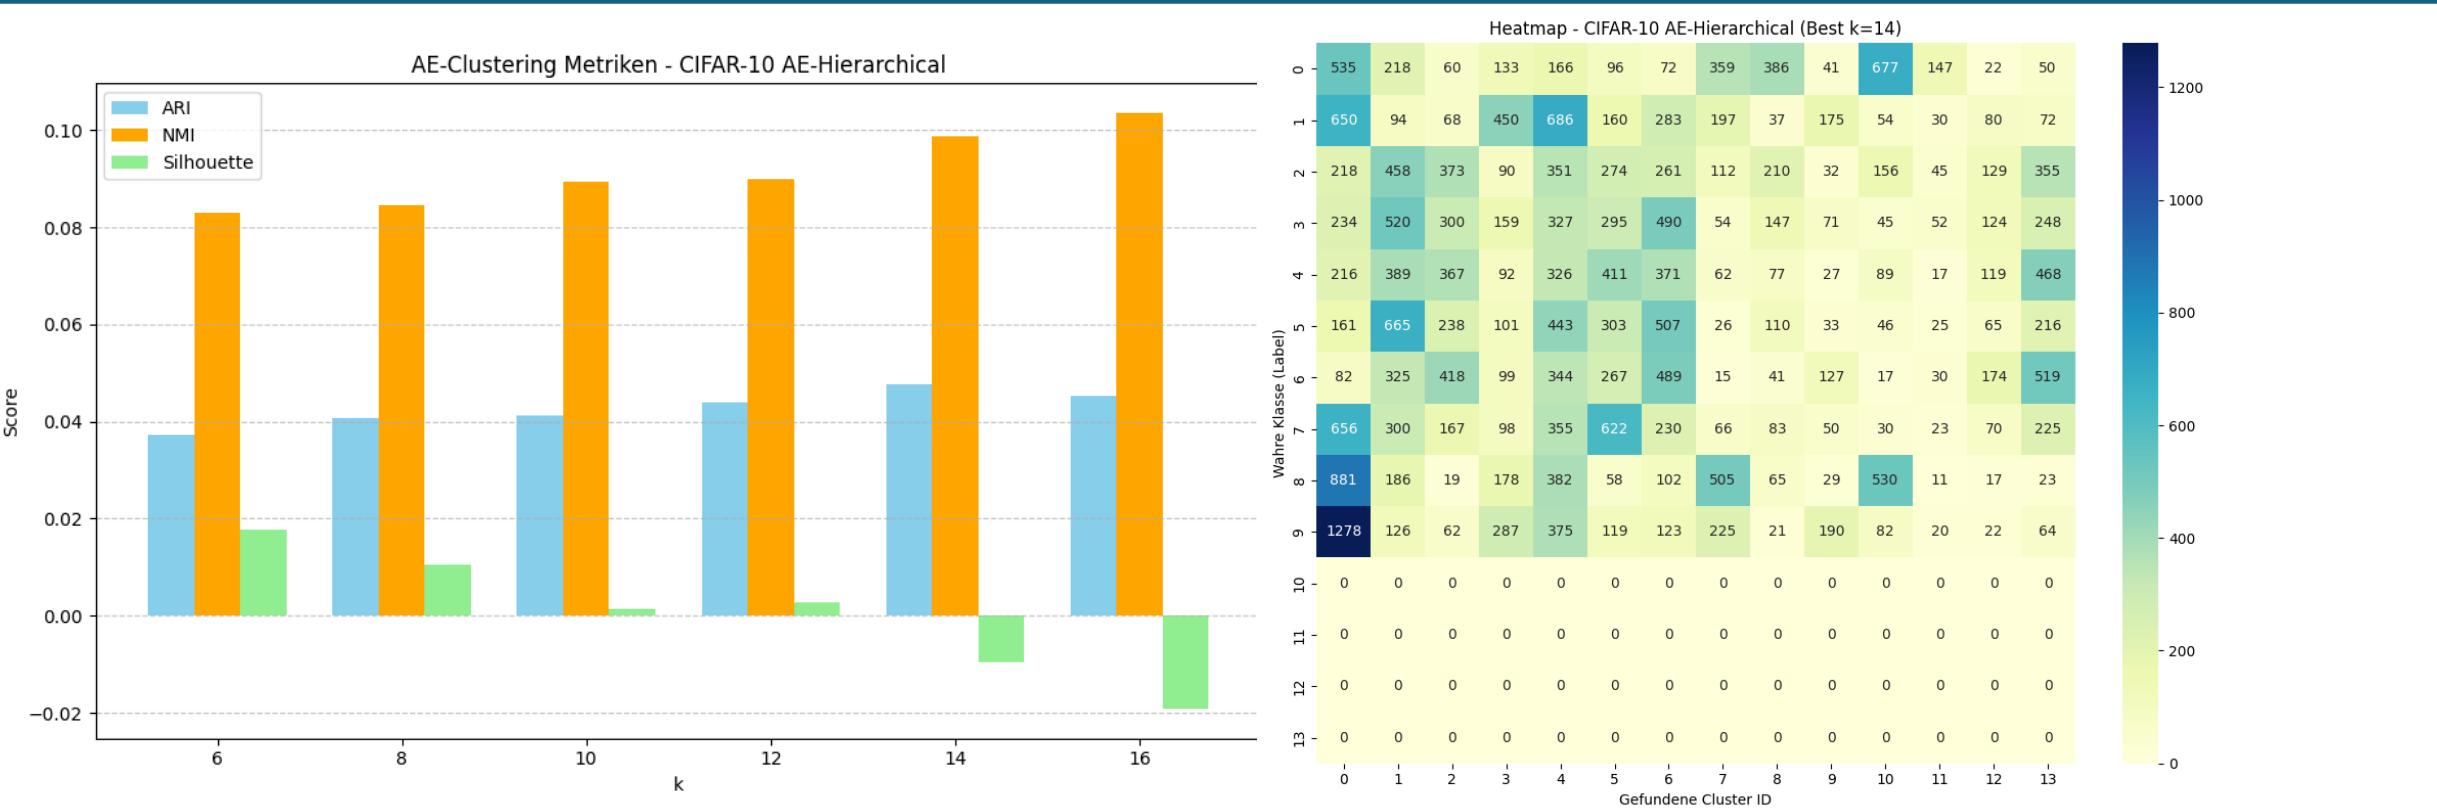
HIERARCHISCHES MIT AUTOENCODER (MNIST)



KMEANS AUTOENCODER (CIFAR-10)



DBSCAN AUTOENCODER (CIFAR-10)



HIERARCHISCHES AUTOENCODER (CIFAR-10)



Epoche 1



Epoche 25



Epoche 50

DCGAN TRAINING (MNIST)

DCGAN Training (CIFAR-10)



Epoche 1



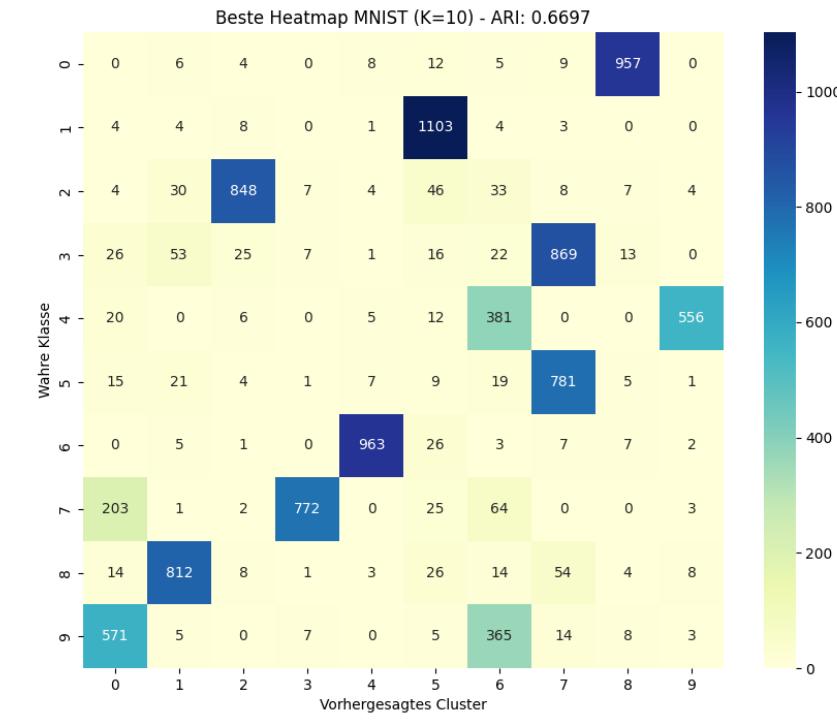
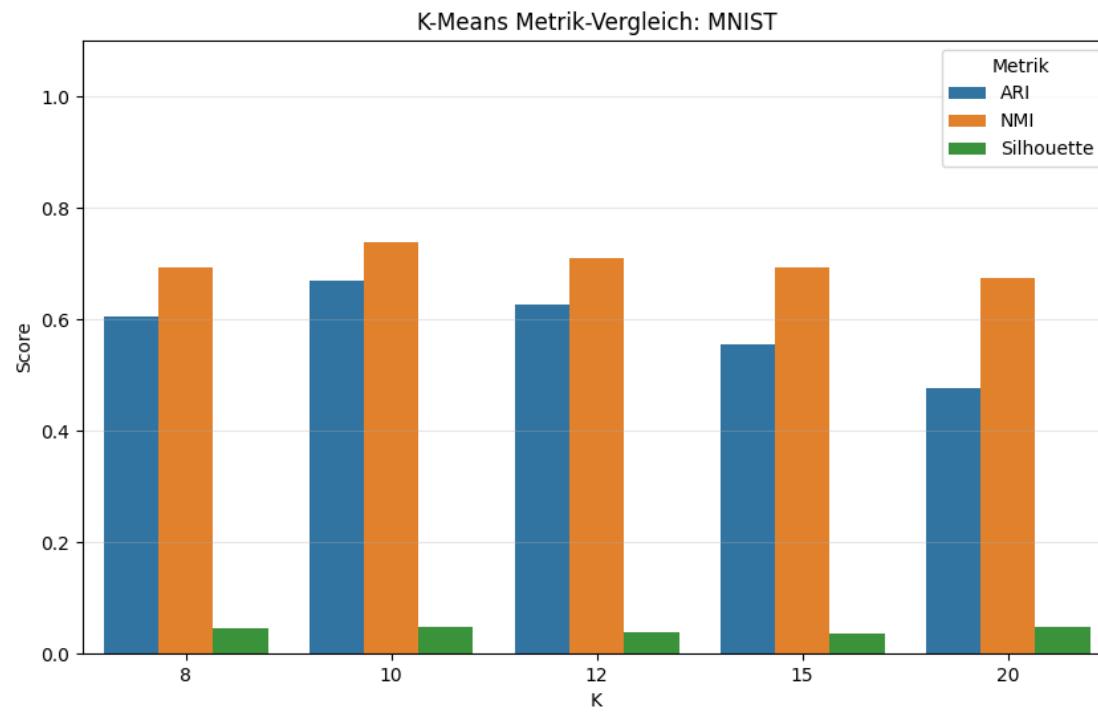
Epoche 35



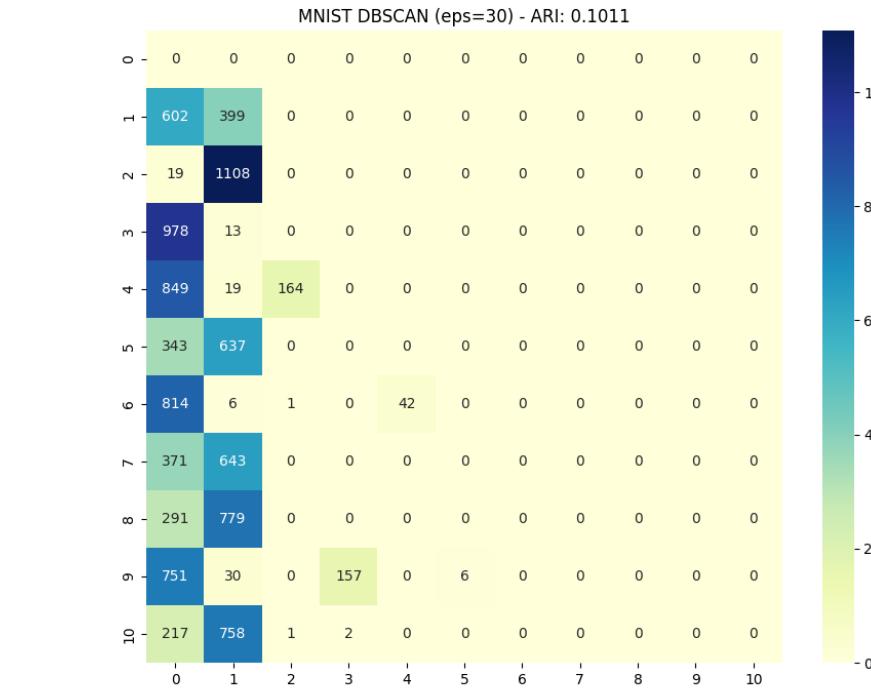
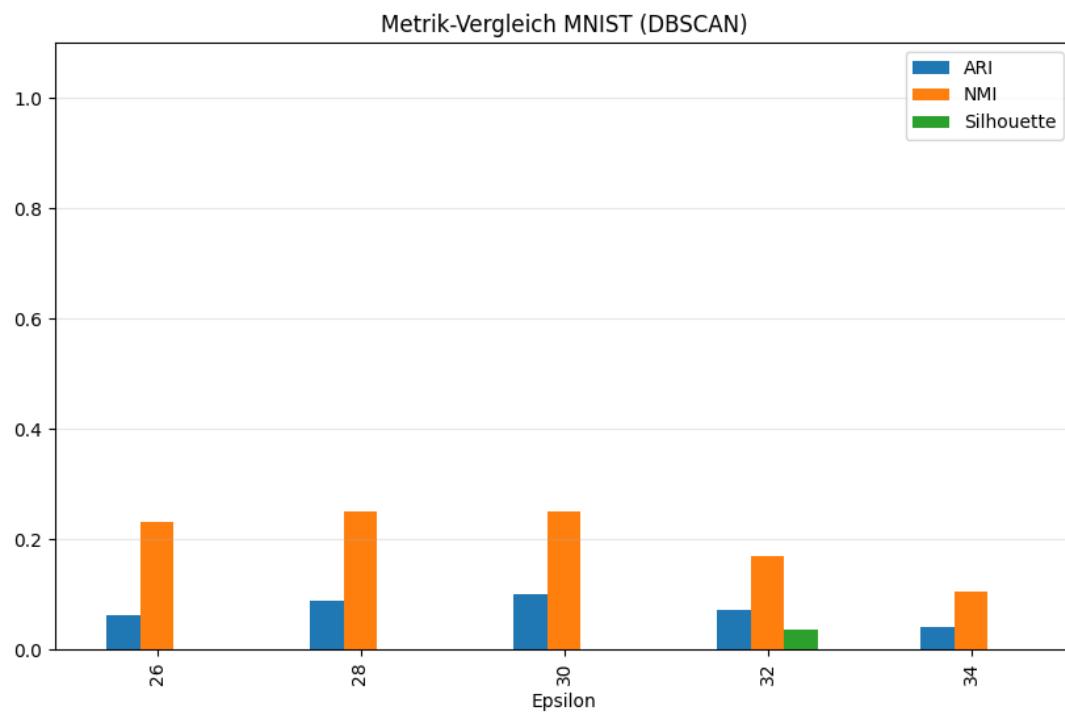
Epoche 75



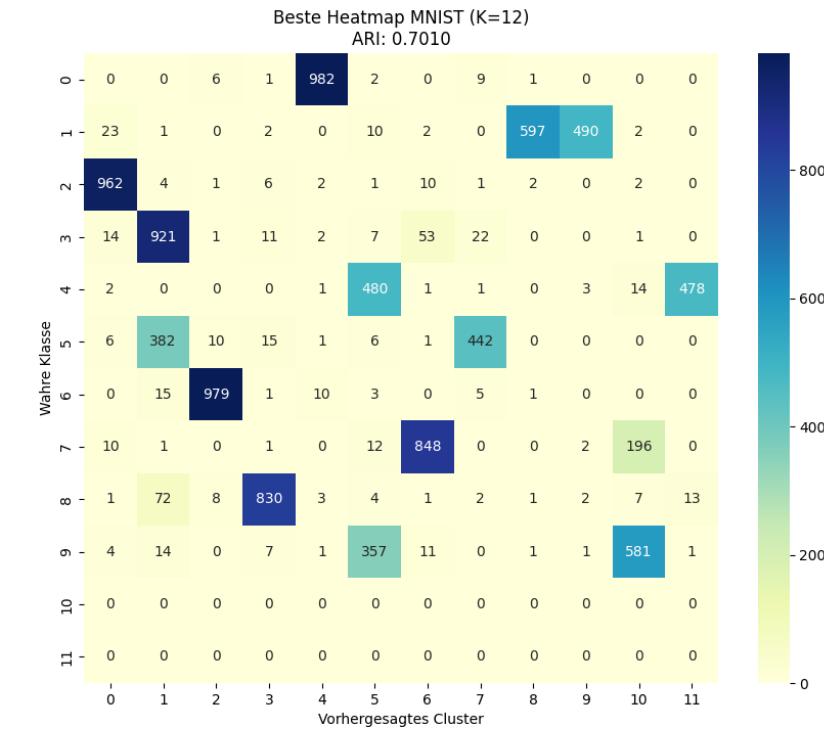
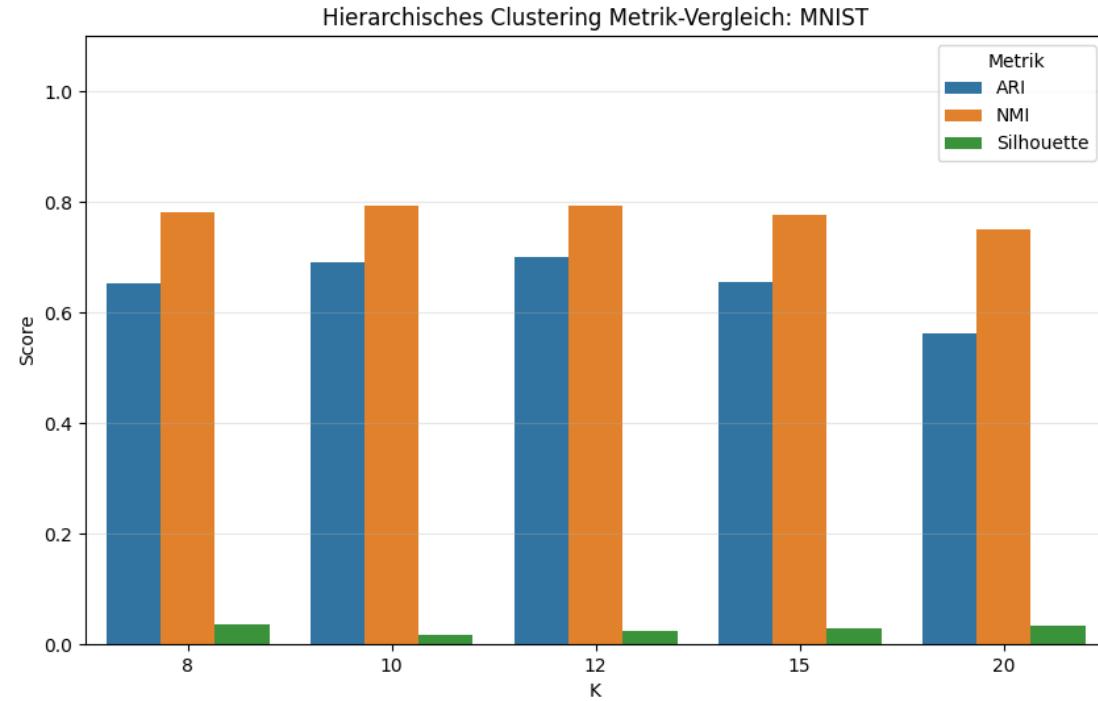
Epoche 100



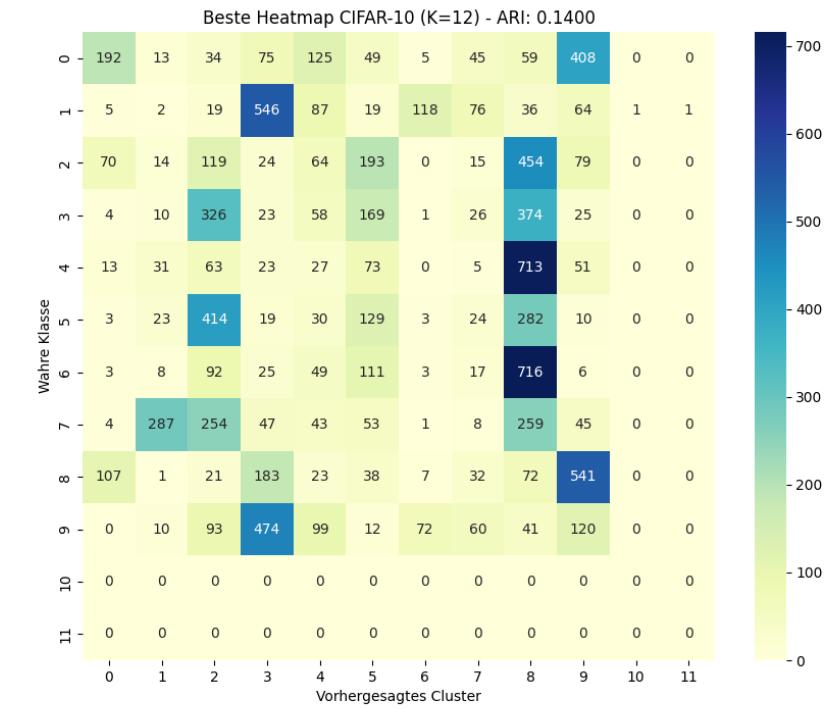
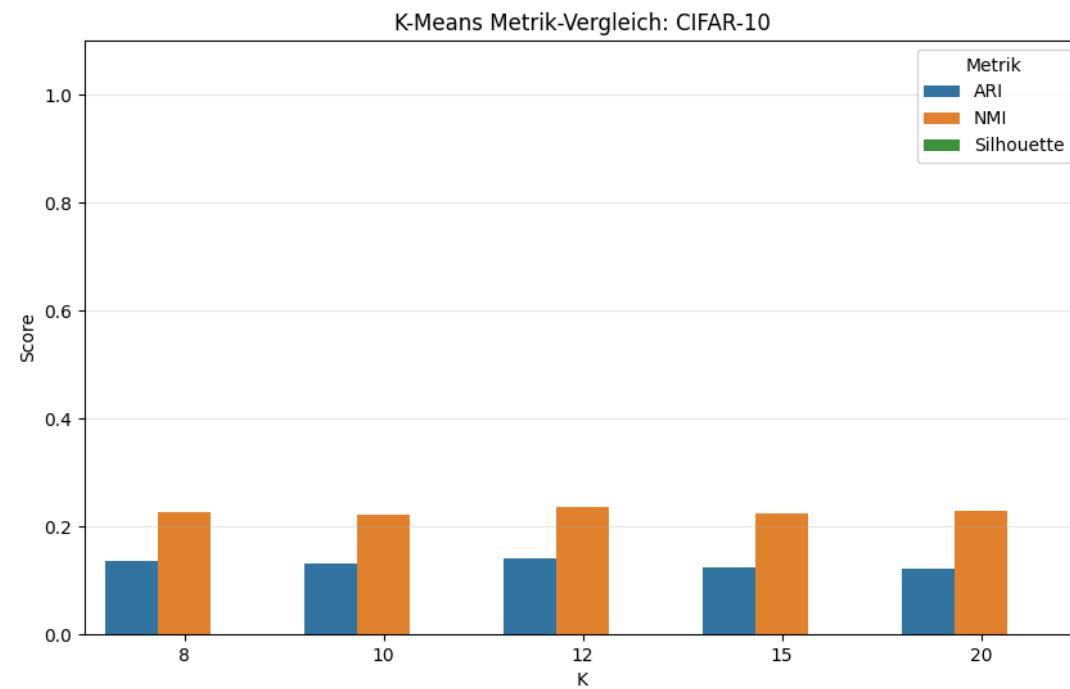
KMEANS MIT DCGAN (MNIST)



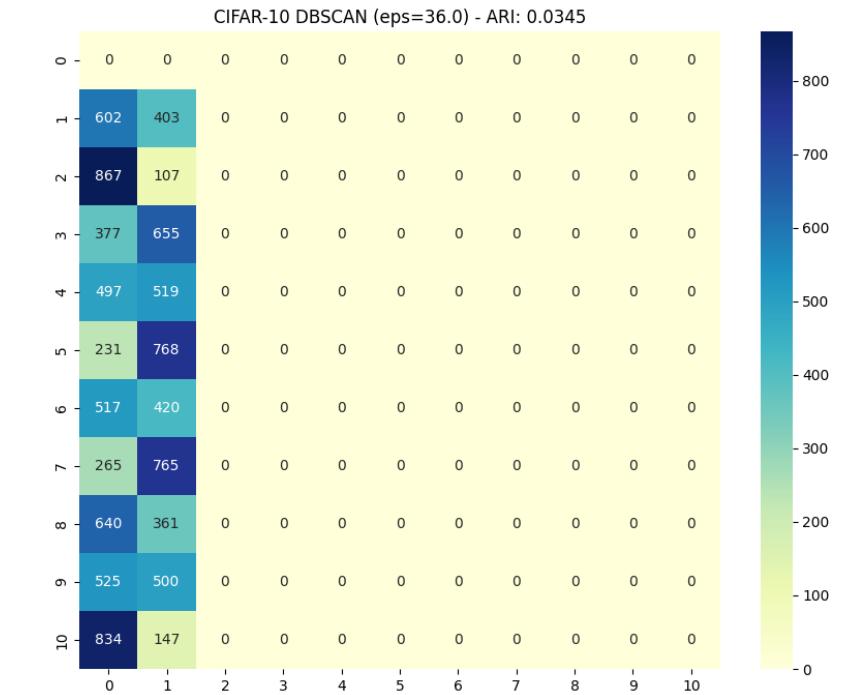
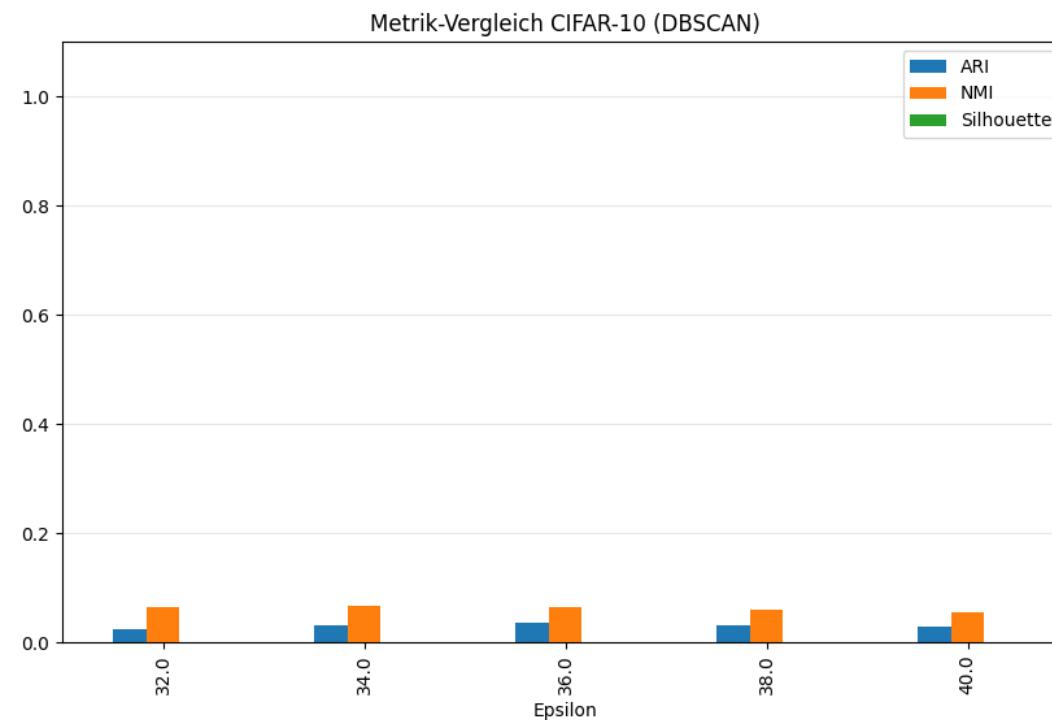
DBSCAN MIT DCGAN (MNIST)



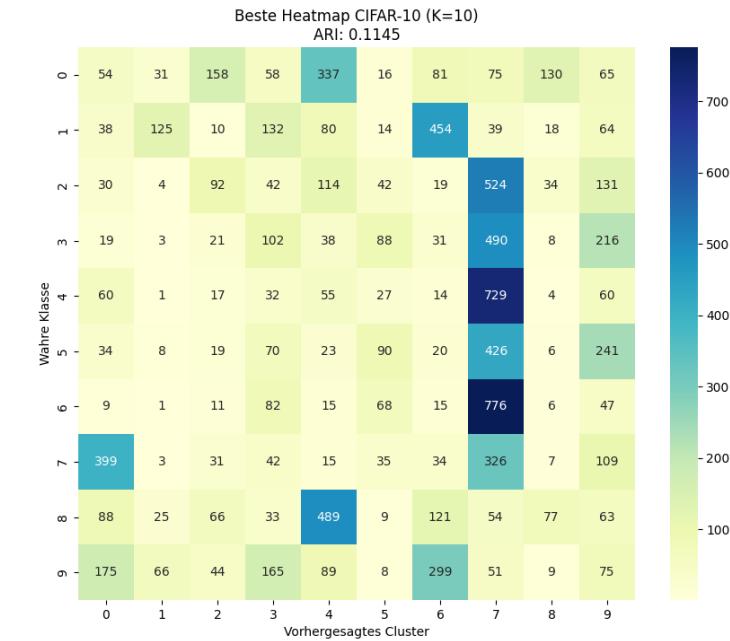
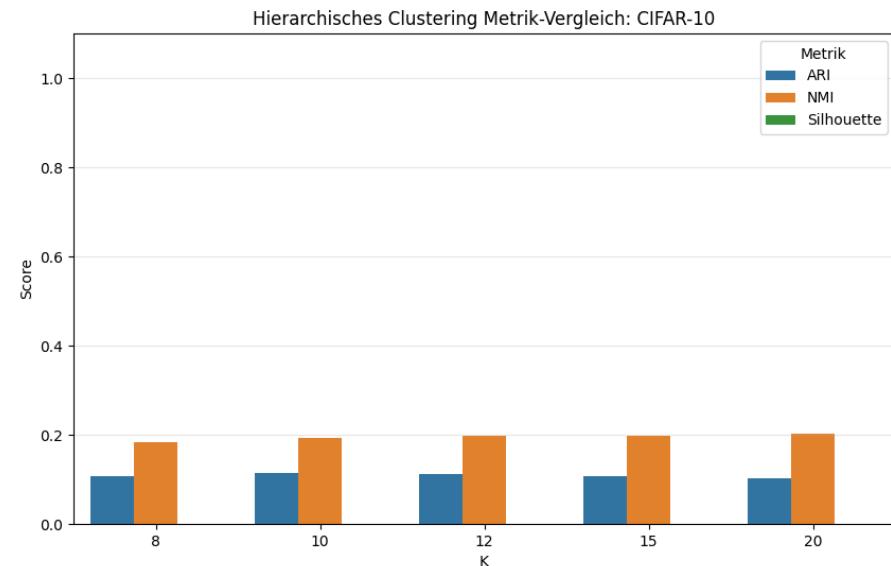
HIERARCHISCHES MIT DCGAN (MNIST)



KMEANS MIT DCGAN (CIFAR-10)



DBSCAN MIT DCGAN (CIFAR-10)



HIERARCHISCHES MIT DCGAN (CIFAR-10)

Fazit

- Clustering auf Rohdaten ist bei komplexen Datensätzen wie CIFAR-10 weitgehend ineffektiv.
- Autoencoder verbessern die Strukturierung, bleiben jedoch durch rekonstruktive Features begrenzt.
- DCGAN-basierte Repräsentationen liefern die besten Ergebnisse durch semantisch diskriminative Merkmale.
- Die Kombination aus DCGAN-Features und hierarchischem Clustering erzielt die höchste Clustering-Qualität.